

ParallelBayes：补充方法、统计与核验记录

中文研究稿：作者与单位待定

2026 年 10 月

本材料保留历史实验的完整数值、诊断、成本口径和跨系统记录，并补充紧凑研究的状态、数值失败、双峰路径及 R 使用费用。原生成段落描述各自批次，不作为新的执行命令。九目标 36 函数的完整紧凑结果、两预算及三种成本口径另见独立结果附录；正文按研究问题选择必要表图。

目录

1	紧凑研究的最终目标与配置	2
2	参考值、数值稳定性与比较敏感性	4
3	水井后验可正规化的充分条件	12
4	紧凑研究的原始路径伴随检查	12
5	紧凑研究的完整状态与使用成本	14
6	历史 CPU 验证与开发证据	16
7	历史 Mac CPU 的冻结实验设计	16
8	历史 CPU 结果与范围	18
9	审查后的伴随分析与 CPU 机制实验	22
10	原生 Windows 扩展：独立开发版本与新冻结实验	28
11	跨系统核验与后续推断比较的边界	32
12	首轮 Windows 的 CUDA 配对点	37
13	首轮 Windows 的 CPU 配对点	38

1 紧凑研究的最终目标与配置

本节直接读取正式紧凑协议及其冻结目标目录，未使用历史 CPU 配置替代本轮定义。全部核和两设备共用每目标的固定仿射坐标。记基础模型坐标为 $r = c + Lq$ ，其中 q 是实际采样坐标；原参数为 $\theta = T_0(r)$ 。除 H2 外 T_0 为恒等映射，H2 再将非中心化变量转换为漏斗原尺度。变换后的密度含 $\log |\det L|$ 。

目标	维数	MALA h	RWM s	固定仿射坐标
G1	8	0.8	0.848528137	$c = 0, L = I$
G2	64	0.4	0.3	$c = 0, L = \text{chol}(\Sigma)$
A1	64	0.4	0.3	$c = m, L = \text{chol}(\Sigma)$
L1	8	0.8	0.848528137	众数及观测信息
L2	8	0.8	0.848528137	众数及观测信息
H1	9	0.480749857	1.66666667	$c = 0, L = I$
H2	9	0.769199771	0.8	$c = 0, L = I$
M1	8	0.8	0.848528137	$c = 0, L = I$
W1	2	1.26992084	1.69705627	众数及观测信息

表 S1: 正式紧凑研究采用的最终配置。 h 遵循正文噪声 $\sqrt{2h}$ 的 MALA 约定； s 是 RWM 提议标准差。表内数字为显示精度，完整浮点数、中心和矩阵保存在随附配置 JSON 及原协议中。

高斯与 AR(1) 目标。 G1 为 $N_8(0, I)$ 。G2 为 $N_{64}(0, U\Lambda U^\top)$ ， $\Lambda_{jj} = 100^{(j-1)/63}$ ； U 由固定 64×64 标准正态矩阵的 QR 分解取得。原始协方差条件数 100，但完整 Cholesky 变换使采样坐标为 $N_{64}(0, I)$ 。A1 的生成模型为 $x_1 \sim N(0, 1)$ 、 $x_t = 0.9x_{t-1} + \sqrt{1 - 0.9^2}\epsilon_t$ 、 $y_t = x_t + \eta_t$ ， $t = 1, \dots, 64$ ，噪声相互独立且为标准正态。记 $K_{ij} = 0.9^{|i-j|}$ ，固定数据后的后验为 $N(m, \Sigma)$ ， $\Sigma = (K^{-1} + I)^{-1}$ 、 $m = \Sigma y$ 。A1 也使用完整 Cholesky 变换，因而采样坐标同为标准正态。G2/A1 的原尺度相关结构不能直接作为本轮核差异的原因；维数、各核移动效率、稠密目标计算及有限精度仍影响被测工作流。

回归目标。 L1/L2 均为 8 参数 logistic 回归，样本数分别为 256/4096，先验 $\beta_j \stackrel{\text{iid}}{\sim} N(0, 2.5^2)$ 。设计矩阵第一列为 1，其余七列从标准正态生成后按每列样本均值和总体式标准差（分母 n ）标准化。生成系数来自 $N_8(0, 2.5^2 I)$ 且两模型共用，观测独立来自 $\text{Bernoulli}(\sigma(X_i\beta))$ 。W1 采用 3020 条真实水井记录， $\Pr(y_i = 1) = \sigma(\alpha + \beta d_i/100)$ ，先验在 (α, β) 上平坦。L1/L2/W1 以零点开始的 trust-exact 优化求众数 c ，接受条件为目标有限及解析梯度最大绝对值不超过 10^{-7} ； $L = \text{chol}(H(c)^{-1})$ 。L1/L2 的 $H = X^\top \text{diag}\{p_i(1 - p_i)\}X + I/2.5^2$ ，W1 不加先验项。优化最多 300 步，未做特征值修复，未使用参考后验样本；这只是固定坐标选择，不将 Laplace 近似当作参考真值。

漏斗与双峰目标。 H1 为 $v \sim N(0, 3^2)$, $x_i | v \sim N(0, e^v)$, $i = 1, \dots, 8$ 。H2 采样 $v \sim N(0, 3^2)$, $z_i \sim N(0, 1)$ 并输出 $x_i = z_i e^{v/2}$ 。二者基础坐标不同, 原参数后验对应。M1 为 $\frac{1}{2}N_8(-5e_1, I) + \frac{1}{2}N_8(5e_1, I)$, 即 $\delta = 5$, 未额外平移或旋转, 因此本例 $q = \theta$ 数值相同, 正文仍统一用 θ 表示原参数。

固定数据的生成与定位。 合成目标使用 NumPy 默认生成器和 SeedSequence。G2、A1 和 logistic 生成系数分别从地址 [20261003, 11] 开始; G2 先生成旋转矩阵, A1 先生成潜状态创新再生成观测噪声。L1/L2 的设计及二元观测分别使用地址 [20261003, 12, n]。相同地址在不同模型内重新开始, 并不表示 G2 与 A1 共用同一目标数组。归档的模型数据和协方差是执行依据, 完整再生成核对最大绝对差小于 10^{-11} 。无需依赖本机目录即可在正式证据包的 `source/benchmark/protocols/windows-native-v1.json` 及 `catalog.json` 定位完整定义; 配置 JSON 还给出来源 SHA 及完整 c, L 。

开发选择、初值与核控制。 坐标构造规则预先固定, 随后在独立开发输入上分别选择 MH 步长, 而非从正式结果重新调参。RWM 候选为 $\{0.5, 1, 1.5, 2.4, 3.5, 5\}/\sqrt{d}$, MALA 候选为 $\{0.1, 0.3, 0.6, 1, 1.6, 2.4\}/d^{1/3}$; 每候选两份四链输入, 丢弃 512 步后保留 1024 步, 以两次均有效时的平均 ESJD/ d 最大者入选, 平局取较小步长。正式四链共用原件中的 $q_0 \sim N(0, 4I)$, M1 首坐标替换为 $(-5, 5, -5, 5)$ 。MH 和 NUTS 读取同一初值, 原尺度初值为 $T_0(c + Lq_0)$; NUTS 另用独立随机流和适应预热, 并非与 MH 共享路径。216 份实际初值逐数组核对通过。

正式保留预算为 1024/4096 步; MH 先丢弃 512 步, 窗口 32, quasi-DEER 每窗口最多 2048 轮, Picard 最多 $N + 512$ 轮。CPU Pyro NUTS 采用四个 spawn 子进程, 每进程一链、一条 torch 计算线程和一条 interop 线程; 每链预热 1024 步、目标接受率 0.8、最大树深 8, 适应步长及对角质量矩阵 (`full_mass=False`), 未使用 JIT。各链适应后的参数保存在输出中, 而非用表内 MH 步长替代。

资源与失败规则。 主 MH 工作进程设置 torch 计算线程 4、interop 线程 1, CUDA 任务也保留这部分主机执行。3888 份主进程环境记录均为上述设置, 浮点数为 float64; OMP/MKL/OpenBLAS/VECLIB 线程环境变量未设置, 因此不将 torch 设置解释为所有库的统一线程硬上限。线程数也不等于独占物理核心预算。每任务存储/工作区估计上限 2048 MiB, 进程树 RSS 监督上限 8 GiB, 原生 Windows Job 提交内存上限 12 GiB; 它们是不同的计量规则, 2048 MiB 不是通用分配器硬上限。任务启动保留可用主存至少 12 GiB 及磁盘至少 4 GiB, CUDA 工作进程另检查 GPU 空闲至少 3 GiB, 运行磁盘底线 1 GiB。边界资源不足则暂停启动, 不把未运行任务标为数值失败; 进程异常、非有限值、迭代耗尽和路径标准失配均保留。没有总实验时限、数值失败重试或顺序回退来改变样本资格。12 GiB 限制本身不证明所见进程失败均由内存耗尽导致。

版本依据。 以上读取的是 windows-compact-inference-v1, 冻结执行源 3a37a89, 协议摘要前缀 91bbff0ec47f。冻结文件和依赖版本保持不变; 本次仅导出配置、核对既有输入, 新增采样和调参均为零。

2 参考值、数值稳定性与比较敏感性

本节直接整理冻结参考和主要实验的保存统计量; 参考偏移分析与后验区间摘要是在收到本轮意见后的伴随分析, 不改变原参考、可用集合或实验协议。

2.1 W1 的逐函数参考

在驻点附近采用固定坐标 $\theta = m + Cz$, 其中

$$m = (0.6059593596, -0.6218819313)^T, \quad C = \begin{pmatrix} 0.0603102245 & 0 \\ -0.0768479318 & 0.0598848727 \end{pmatrix}.$$

驻点由解析 NumPy 梯度求得, 最大梯度绝对值为 8.68×10^{-14} ; CC^T 为该点观测信息的逆。在 $[-R, R]^2$ 内作张量 Gauss-Legendre 求积, $R \in \{6, 8, 10, 12\}$, 每轴阶数 $n \in \{32, 64, 96\}$, 保留全部 12 个结果。事件 $\beta > 0$ 另按边界分段积分。使用预先选定的 $(R, n) = (12, 96)$, 没有按与 MCMC 的接近程度选择参考。

函数	求积参考	加密变化	扩域变化	MCMC 减求积	MCMC MCSE
α	0.606577112	4.44×10^{-16}	2.22×10^{-16}	1.33×10^{-4}	6.33×10^{-4}
β	-0.622983250	2.22×10^{-16}	6.66×10^{-16}	8.40×10^{-4}	0.00104
α^2	0.371577055	2.22×10^{-16}	5.55×10^{-16}	1.36×10^{-4}	7.68×10^{-4}
β^2	0.397618708	2.22×10^{-16}	7.77×10^{-16}	-0.00109	0.00135
$p(0)$	0.647037397	6.66×10^{-16}	0	3.13×10^{-5}	1.44×10^{-4}
$p(100)$	0.495902581	2.22×10^{-16}	2.22×10^{-16}	2.43×10^{-4}	1.58×10^{-4}
$\mathbf{1}(\beta > 0)$	4.767209×10^{-11}	1.77×10^{-24}	4.76×10^{-24}	-4.77×10^{-11}	未定

表 S2: W1 参考精度摘要。加密变化为 $R = 12$ 时 64 到 96 阶之差; 扩域变化为 96 阶时 $R = 10$ 到 12 之差。后两列来自独立的既有 Stan 参考; MCSE 取 posterior、链间均值和批均值三种估计的可用最大值。上述变化是数值稳定性指标, 不是认证误差界。

独立 MCMC 参考来自 posteriorDB 的一次 Stan 生成: 10 链, 每链总迭代 20000、预热 10000、每 10 步保留一次, 得到每链 1000 个相关样本; 不是 10000 个独立实验。六个连续函数的 MCSE 为有限估计, 不能约束共同偏差。事件样本全部为零, MCSE 仍未定。

基于全局对数凹性支持平面的尾部积分不等式, 256 个角扇区给出的 $R = 12$ 尾质量/计算归一化常数为 7.47×10^{-30} 。这是浮点计算的尾部上界估计, 不包含区间算术认

证、内部求积或舍入误差。六个连续均值从 $R = 6$ 到 12 的最大变化约 1.87×10^{-9} ；事件由 4.34669×10^{-11} 变为 4.76721×10^{-11} 。完整 12 组值及各函数尾部估计保存在参考伴随数据中。

2.2 L1/L2 有限参考及已有偏移分析

目标	函数	参考均值	批均值 MCSE	拟合间 MCSE	采用 MCSE
L1	θ_1	-0.278065574	3.89×10^{-4}	2.59×10^{-4}	3.89×10^{-4}
L1	θ_2	-0.678895426	5.00×10^{-4}	3.55×10^{-4}	5.00×10^{-4}
L1	$\sigma(\theta_1)$	0.431794752	9.41×10^{-5}	6.09×10^{-5}	9.41×10^{-5}
L1	$\mathbf{1}(\theta_1 > 0)$	0.109191895	6.59×10^{-4}	7.64×10^{-4}	7.64×10^{-4}
L2	θ_1	-0.311176772	8.89×10^{-5}	8.69×10^{-5}	8.89×10^{-5}
L2	θ_2	-0.600525763	1.02×10^{-4}	7.79×10^{-5}	1.02×10^{-4}
L2	$\sigma(\theta_1)$	0.422880789	2.17×10^{-5}	2.12×10^{-5}	2.17×10^{-5}
L2	$\mathbf{1}(\theta_1 > 0)$	0	未定	未定	未定

表 S3: L1/L2 逐函数有限参考。每模型四份独立四链拟合，每链保留 16384 步，共 262144 个相关样本；参考是归档 reference-v1 的既有 BlackJAX NUTS 结果。L2 符号事件的原始机械方差计算为零，正式不确定性仍保留未定。

四份参考拟合的种子与主要实验分离，模型数据和目标哈希经复用审查一致；每链预热 1024 步，最大树深 10。四份拟合未记录发散，但这些检查不能排除参考的共同偏差。MCSE 取批均值与拟合间估计的较大者。L1 符号事件出现 28624 次，L2 为零；后者不能作为精确零概率参考。

原正式分析已对有限 MCMC 参考作共同偏移 $\mu^* \pm 2 \text{MCSE}$ 敏感性计算。在 4096 预算 CPU 顺序 MALA 与 CPU Pyro NUTS 的比较中，L1 四函数及 L2 前三函数的损失差在该范围内均保持正号；但每格仅六个共同有效重复，未达到 20 份的区间计算下限。L2 符号事件保持未定。逐函数上下限保存在参考伴随 JSON；这一偏移范围不是置信区间，且没有扣除参考方差。

2.3 W1 比较对参考偏移的敏感性

在相同可用重复集合和同一尺度 $s_f = 1$ 下，记两方法平均平方损失差为 $D_f(c)$ ，参考从 c 移至 $c + e$ 时有

$$D_f(c + e) = D_f(c) - 2e \left(\widehat{\mu}_{A,f} - \widehat{\mu}_{B,f} \right).$$

这里 A 是 CPU 顺序 MALA、 B 是 CPU Pyro NUTS 四进程工作流。本表固定共同集合以对应配对比较；改用各自集合会改变所比较的估计对象。若尺度不同，共同平方项

函数	$D_f(c)$	e_0	改用 MCMC 参考	± 2 MCSE 偏移范围
α	3.06×10^{-7}	8.55×10^{-4}	2.58×10^{-7}	-1.47×10^{-7} 至 7.58×10^{-7}
β	5.88×10^{-7}	-6.56×10^{-4}	1.34×10^{-6}	-1.27×10^{-6} 至 2.44×10^{-6}
α^2	4.90×10^{-7}	0.00107	4.28×10^{-7}	-2.11×10^{-7} 至 1.19×10^{-6}
β^2	1.02×10^{-6}	8.41×10^{-4}	2.35×10^{-6}	-2.27×10^{-6} 至 4.32×10^{-6}
$p(0)$	1.57×10^{-8}	1.94×10^{-4}	1.31×10^{-8}	-7.67×10^{-9} 至 3.90×10^{-8}
$p(100)$	1.67×10^{-9}	-1.24×10^{-5}	3.43×10^{-8}	-4.08×10^{-8} 至 4.41×10^{-8}

表 S4: W1 的参考敏感性。正号表示本格 NUTS 工作流的平均平方损失较小。末列只是以独立 MCMC 的 MCSE 作为假设偏移尺度，不是求积误差估计，也不是置信区间。

一般不再抵消。下表固定 4096 预算和全部 24 份共同有效重复。 e_0 为使点损失差变为零的带符号参考偏移；若两方法平均估计相同，该阈值不存在。

六个连续函数在全部 12 个保存求积值以及独立 MCMC 参考点下保持相同点排序；在假设 ± 2 MCSE 偏移内，六者均可改变符号。因此数据支持对已检查参考点的稳定性，尚不提供对未知真值的认证排序。W1 的 $p(100)$ 即使在固定参考下，其原逐点 BCa 损失差区间也包含零。其余五个连续函数的固定参考区间不包含零；这些区间不传播求积参考的不确定性，也未校正多重比较。

所有 W1 拟合的 $1(\beta > 0)$ 均值都是零；图中的非零平方差完全由共同数值参考决定。改变共同参考仍使两方法该函数的点损失差为零，这既不确认极小尾概率的估计精度，也不解决常量函数诊断的未定状态。

2.4 W1 模型给出的后验解释

参数或概率	后验均值	95% 等尾后验区间	均值 MCSE
α	0.606710	[0.488359, 0.723356]	6.33×10^{-4}
β	-0.622143	[-0.810761, -0.429960]	0.00104
$p(0)$	0.647069	[0.619720, 0.673346]	1.44×10^{-4}
$p(100)$	0.496146	[0.465215, 0.526176]	1.58×10^{-4}

表 S5: 独立既有参考样本的应用摘要。距离以 100 米为单位， $p(0) = \sigma(\alpha)$ ， $p(100) = \sigma(\alpha + \beta)$ 。区间为 10000 个保存相关样本的经验 2.5% 与 97.5% 分位数（R type 7 等价规则）；它描述后验不确定性，均值 MCSE 描述有限计算误差。分位数本身的估计误差没有另行量化。

该二维模型中，较远距离与较低的换井概率相联系。以上为已指定模型及其参考样本的后验描述，不把距离系数解释为因果效应；也没有从正式实验中挑选表现较好的拟合。

来源与重建。表格由随附的参考精度脚本从 W1 求积与参考档案、L1/L2 参考摘要，以及 Mac 独立重建的正式统计生成。脚本校验目标、参考二进制和读取的统计文件哈希；参考伴随 JSON 同时保存完整逐函数数值、所有 12 个求积配置、两预算配对结果和来源 SHA。没有新增 MCMC 或更换原正式参考。

后续参考计算。以上四小节保留原参考及首次伴随分析；其中“尚未认证”描述该分析完成时的状态。随后完成的 L2 重要性参考见下节，W1 有限域、尾部和舍入误差的数值包络及其排序影响见第2.6–2.7节。原参考文件、原图表和重复实验的不确定性区间不作追溯替换。

2.5 L2 稀有符号事件的独立重要性参考

原 NUTS 参考的 262144 个相关样本中， $\mathbf{1}(\theta_1 > 0)$ 恒为 0。为研究这一事件的概率尺度，另以协议 `l2-rare-reference-is-v1` 进行独立重要性采样，保持原八参数 logistic 数据、坐标与独立 $N(0, 2.5^2)$ 先验不变。以下是新增参考分析，前文的原参考表保留其历史未定状态。

提议密度为 $q = 0.45q_t + 0.45q_+ + 0.10p_0$ ： q_t 是在无约束众数附近的自由度 5 多元 t ， q_+ 是事件约束众数附近、截断到 $\theta_1 > 0$ 的多元正态， p_0 为原先验。曲率矩阵由负对数目标 Hessian 构造，特征值下限为 $\max(10^{-12}, 10^{-10}\lambda_{\max})$ ，记录修复前后谱。边界众数的首坐标标准差取局部逆信息标准差与向外对数目标斜率绝对值倒数中的较小者，其余条件协方差与回归系数保留；优化最多 1000 轮。事件正态先抽截断的首坐标边缘，再抽其余条件坐标，不把负数裁成 0。

每点独立选择组件，分母使用完整、带常数的混合密度，权重为 $w = L(\theta)p_0(\theta)/q(\theta)$ 。对数域计算避免下溢。自归一化重要性估计与防御混合的原则见 [19]；本研究的配比、尺度与预算另行规定。由于 $L \leq 1$ 且 $q \geq 0.10p_0$ ，理论上 $w \leq 10$ ，但该界本身不保证罕见事件的相对精度。

预定 t /事件正态标准差倍数组合为 (1, 1)、(1.5, 0.5)、(2, 0.25) 及 (3, 0.125)，每组试探 4096 点，按比率影响量的估计相对方差选前两组，记为 Q_1, Q_2 。全部 16384 个试探点排除。两组各用 8 个独立 PCG64 批次，每批固定 2^{17} 点，正式点数共 2097152；较早检查点只检查资源和计算，不依概率估计提前停止。没有新增 MCMC 拟合。

设第 k 批的分子、分母均值为 $A_k = n^{-1} \sum_i w_{ki} \mathbf{1}(\theta_{ki,1} > 0)$ 和 $B_k = n^{-1} \sum_i w_{ki}$ ，则

$$\hat{p} = \frac{\bar{A}}{\bar{B}}, \quad \widehat{\text{MCSE}}^2 = \frac{S_{AA} - 2\hat{p}S_{AB} + \hat{p}^2 S_{BB}}{8\bar{B}^2},$$

其中 S 是 8 对批次均值的样本协方差，分母为 7。计算对 A, B 使用相同对数缩放，不平均各批次比率。该 MCSE 是 delta 近似；有限样本比率有偏，8 批估计不能提供严格误差认证或保证区间覆盖率。

两套提议均达到预设门槛：相对 MCSE 不超过 10%，事件/分母权重 ESS 至少 200/1000，最大事件/分母权重不超过 0.05/0.01；估计差不超过 3 倍合并 MCSE。后者仅作相容性诊断。 Q_2 的事件权重更集中，整体门槛通过没有消除批次间波动（表S8）。

提议	$\hat{p}$	近似 MCSE	相对 MCSE
Q1	1.56548×10^{-9}	5.691×10^{-12}	0.364%
Q2	1.76048×10^{-9}	1.244×10^{-10}	7.067%

表 S6: L2 事件的两套独立重要性参考。每套 8 个独立批次、1048576 个正式点；两套结果均报告。

提议	事件权重 ESS	分母权重 ESS	最大事件权重	最大分母权重
Q1	176551.83	356889.74	7.729×10^{-4}	4.673×10^{-6}
Q2	220.20	161503.98	2.486×10^{-2}	1.071×10^{-5}

表 S7: 全部正式点的权重质量。事件 ESS 为 $(\sum wI)^2 / \sum (wI)^2$ ，分母 ESS 同理；最大权重均已在相应和中归一化。它们不是 MCMC ESS，也不是独立批次数。

批次	Q_1			Q_2		
	$10^9 \hat{p}_k$	事件 ESS	最大权重	$10^9 \hat{p}_k$	事件 ESS	最大权重
1	1.56971	30841.72	0.00178	1.38805	52.98	0.08752
2	1.56344	15594.55	0.00479	2.40679	21.73	0.14497
3	1.54298	34723.54	0.00166	1.49625	32.35	0.14431
4	1.58975	11680.96	0.00610	1.81776	34.88	0.09180
5	1.55017	31624.24	0.00196	1.87554	29.62	0.12767
6	1.56554	38343.14	0.00085	1.47945	37.54	0.10601
7	1.58537	20594.82	0.00272	2.06896	21.85	0.14655
8	1.55717	23105.89	0.00341	1.54346	41.84	0.09761

表 S8: 八个独立批次的完整结果；每批 131072 点。批次比率仅用于展示波动，表S6使用总分子与总分母的比率。最大权重是批内归一化事件权重，不能与整套提议的最大权重混用。

原 L2 的 432 项主任务有 414 项有效、18 项失败，所有有效输出的事件均值均为 0。相对于两套参考，该事件单独的原尺度平方差分别为 2.451×10^{-18} 和 3.099×10^{-18} ；参考的近似一阶误差传播为 $2\widehat{p}\widehat{\text{MCSE}}$ 。这不是重新计算原全函数达标率，也不修复常量链诊断。全零估计相对于两套正概率参考的相对误差均为 100%。

独立核验读取 633 件资产，从保存权重以补偿求和重算比率、权重 ESS 和 MCSE，并在 96 个预定或极值点独立重算目标与完整提议密度；最大 log 权重差为 3.64×10^{-12} 。恢复检查新增随机点和权重块均为 0。原参考及主任务结果未被覆盖，代码、批次表和来源 SHA256 随补充分析提供。

2.6 W1 后验参考的数值包络

为区分参考值的数值误差与 MCMC 估计误差，另立协议计算 W1 七个后验函数的包络。对象仍为原 3020 条观测、两个回归参数和平坦先验；数据与距离除以 100 的运算沿用原 binary64 值。记原坐标为 $\theta = (\alpha, \beta)^\top = c + Az$ ，固定 A 为对角元为正的上三角矩阵，令

$$g(z) = |\det A| \exp\{\ell(c + Az) - \ell(c)\}, \quad \mathbb{E}[f(\theta)] = \frac{\int f(c + Az)g(z) dz}{\int g(z) dz}.$$

c, A 按协议中的精确二进制常数解释；变换可逆即可，不要求 c 恰为后验众数。记 $\sigma(t) = \{1 + \exp(-t)\}^{-1}$ ，六个连续函数为 $\alpha, \beta, \alpha^2, \beta^2, \sigma(\alpha), \sigma(\alpha + \beta)$ ，另有 $\mathbf{1}(\beta > 0)$ 。有限区域为 $[-12, 12]^2$ ，沿 $z_2 = -c_2/A_{22}$ 分为两个矩形；事件的分子是正侧区域内的密度积分，避免对指示函数使用光滑求积余项。

有限域与舍入误差。 采用两点 Gauss–Legendre 和 Simpson 张量规则分别细分。记 I_j, Q_j 为第 j 坐标的积分与求积算子。对任一被积函数 ψ ，设单元边长为 h_1, h_2 ， M_1, M_2 分别包络该单元内 ψ 的两项纯四阶偏导绝对值，则

$$|I_1 I_2 \psi - Q_1 Q_2 \psi| \leq \frac{h_2 h_1^5 M_1 + h_1 h_2^5 M_2}{C}, \quad C = \begin{cases} 4320, & \text{两点 Gauss,} \\ 2880, & \text{Simpson.} \end{cases} \quad (1)$$

一维余项见 [20]；这里 h_j 是整个单元边长。张量界由 $I_2(I_1 - Q_1) + Q_1(I_2 - Q_2)$ 分解及正权重之和等于边长得到。被积函数和四阶偏导使用 logistic 导数、指数函数求导和乘积法则构造；对数似然凹性给出单元中点支持平面的密度上界。区间评价覆盖整个单元，不用两规则结果的差替代余项。

函数、节点、导数和累计误差通过 python-flint 调用 Arb 球算术 [21]。128、256、384 bit 的固定粗网格用于数值稳定性检查，正式自适应细分使用 384 bit；有效误差包络来自式(1)和向外舍入，而非高精度数值彼此接近。事件边界虽以球表示，其不确定性同时传入节点、单元宽度和导数范围。独立检查从保存的二进制中点和半径还原精确有理端点，重建区域覆盖及全部叶单元的积分和余项之和。

尾部与归一化。 令 $H(z) = \ell(c + Az) - \ell(c)$ 。把圆周分为 256 个扇区, 半角为 $\Delta = \pi/256$, 中心单位方向为 u_k , 切向方向为 v_k 。在 $R = 12$ 处计算

$$a_k = u_k^\top \nabla H(Ru_k), \quad b_k = v_k^\top \nabla H(Ru_k), \quad \kappa_k = -\{a_k \cos \Delta + |b_k| \sin \Delta\}.$$

当 $a_k < 0$ 且 $\kappa_k > 0$ 得到区间确认时, 凹性支持平面使该扇区内任意 $r \geq R$ 的方向 u 满足

$$g(ru) \leq |\det A| \exp(C_k - \kappa_k r), \quad C_k = H(Ru_k) - Ra_k.$$

因此圆盘外质量的上界为

$$B_0 = \sum_k 2\Delta |\det A| e^{C_k - \kappa_k R} \left(\frac{R}{\kappa_k} + \frac{1}{\kappa_k^2} \right). \quad (2)$$

圆盘包含于所积分方形, 故圆盘外的界同时覆盖方形外遗漏部分。对于一、二阶矩, 另用 $|\theta_j| \leq |c_j| + \|A_j\|r$, 将右侧及其平方乘入径向积分, 分别得到 $B_{|\alpha|}, B_{|\beta|}, B_{\alpha^2}, B_{\beta^2}$; 质量界 B_0 不能直接替代矩尾界。两项预测概率及事件均在 $[0, 1]$ 内, 其尾项可由 B_0 包络。

有限域分母区间加上 $[0, B_0]$; 有符号的一阶矩分子加上 $[-B_{|\theta_j|}, B_{|\theta_j|}]$, 非负分子先与 $[0, \infty)$ 相交, 再加入相应非负尾项。只有归一化常数下界严格为正时, 才以分子、分母的四端点比率形成后验区间。两规则均有效且相交时另列交集; 不相交则保留原件并调查。两规则共享目标、导数及尾界实现, 因此不是完全独立的正确性证明。

精度与计算边界。 预设六个连续函数的区间半宽目标为 10^{-8} , 事件半宽不超过 10^{-13} 且相对中点不超过 1%。每规则最多 2^{18} 个活动单元、1999000 次按协议计数的评价, 另保留 2000 次共享额度, 合计不超过 4000000 次; 计数包含向量函数、导数界及共享中点的目标评价, 并保留中断前预留的工作。达到工作量、内存或存储保护时输出当前状态, 宽但有效的区间与未确定的分母分别记录, 不因未达精度删除结果。最终逐函数区间和停止原因由独立核验后的记录生成。

对既有比较的影响。 原主实验和参考文件保留。设既有有效重复上的两种方法函数估计为 U_r, V_r , 共同参考为 c_f ; 其经验平方差之差为

$$D(c_f) = \overline{U^2 - V^2} - 2c_f \overline{U - V}.$$

在 $c_f \in [l_f, u_f]$ 上, D 的范围由两端点给出; 单方法平方差的最小值在样本均值向该区间的投影处, 最大值在端点之一。计算保持原共同有效重复和 $s_f = 1$ 尺度, 另列全部计划分母。范围不跨零只说明点排序对该数值参考区间稳定, 不代替重复实验的不确定性、失败率或后验探索诊断。

2.7 W1 包络结果与既有比较

两种规则分别在 31533 和 37671 个活动单元达到全部七函数的预设精度；按协议预留口径合计 1351046 次评价，未新增 MCMC 拟合。完整原件的 24 份资产、两个区域的覆盖、叶单元求积与余项累计、有符号比率和交集均通过精确有理端点核对。两种求积的共同实现范围见第2.6节。

函数	后验期望区间	Gauss/Simpson 达标
α	[0.606577102075, 0.606577121451]	是/是
β	[-0.622983259465, -0.622983239584]	是/是
α^2	[0.371577048819, 0.371577061368]	是/是
β^2	[0.397618700920, 0.397618714571]	是/是
$p(0)$	[0.647037387034, 0.647037407034]	是/是
$p(100)$	[0.495902573466, 0.495902588876]	是/是
$\Pr(\beta > 0)$	[0.000000000047671124, 0.000000000047673026]	是/是

表 S9: W1 后验函数的数值包络交集。端点向外舍入；各规则的精度状态由未舍入区间判断。连续函数半宽目标为 10^{-8} ，事件半宽目标为 10^{-13} 且相对半宽不超过 1%。

两种规则的七函数均达到预设目标。

表中连续函数以 12 位小数、事件以 18 位小数向外舍入；精度是否达标使用原二进制区间判断，因此十进制展示宽度可能略大于停止阈值。原七个求积参考点全部位于相应交集内，原参考文件和主结果表保持不变。

对原 432 份有效 W1 拟合（九 workflow、两预算，每格 24 份四链重复），传播区间得到 126 项单方法平方差范围和 504 项配对损失差范围。连续六函数各有 68 项符号固定、4 项恒等；事件的 72 项比较全部恒等。合计 408 项符号固定、96 项恒等，没有相对原参考点的符号翻转或跨零未定项。数值符号稳定包含极小的浮点路径差异，并不说明效应有实际意义或在重复实验中显著；主实验的逐点不确定性区间继续单列。

全部 W1 事件估计为零，而表中概率区间严格为正，故事件估计相对该参考的误差为 100%。其绝对平方差约为 2.27×10^{-21} ，说明极小的绝对损失仍可与未观察到罕见事件同时出现；常量函数的链间诊断保持未定。

恢复检查复用全部 24 份原科学资产，新增被积函数评价为零，文件哈希未变。本地归档含 81 个内容成员；在同机独立目录从归档源码和输入重建后，九份核验/报告文件及两份校验清单逐字节相同。该检查确认可搬移重建，不替代对导数与尾界实现的数学条件，也不是异机独立研究复现。

3 水井后验可正规化的充分条件

仅有截距和距离系数两个参数，且平坦先验相对于 $d\alpha d\beta$ 定义。保存数据的 1 基行号 533/531 在 3.25200009346008 米分别对应结局 0/1；2884/190 在 151.065994262695 米对应 0/1。实际协变量为距离除以 100，记两个不同值为 a, b 。设 $g(v) = \sigma(v)\{1 - \sigma(v)\}$ ，选取上述四个似然因子，其余因子均不超过 1，故

$$L(\alpha, \beta) \leq g(\alpha + a\beta)g(\alpha + b\beta).$$

因为 $\int_{\mathbb{R}} g(v) dv = 1$ 且变量变换行列式绝对值为 $|b - a| > 0$,

$$0 < \int_{\mathbb{R}^2} L(\alpha, \beta) d\alpha d\beta \leq \frac{1}{|b - a|} < \infty.$$

因此该二维模型后验可正规化。归档证书使用较松的指数包络及 $4/|b - a|$ 上界，同样有效，原件保留。此证明不认证数值求积参考的有限区域误差或稀有事件精度，也不直接适用于另加回归系数的模型。

4 紧凑研究的原始路径伴随检查

4.1 内部停止与外部路径标准

完整正式原件经分块和成员 SHA 校验后，另读取全部 42 项数值失败：quasi-DEER MALA 在 CPU/CUDA 的 1024 预算各 7 项、4096 预算各 13 项；顺序 MALA 在两设备的 4096 预算各 1 项。它们均来自中心化漏斗 H1。候选输出的内部状态为完成，最终状态则由外部路径审计置为失败；状态链与原随机数组分别核对，没有重分类。

Mac 使用冻结的独立 NumPy 递推、实际初值和输入数组复核 602112 次转移，42 份仍全部越过原完整路径界限；接受事件计数均与保存输出一致。最大绝对路径差为 5.72867×10^{-3} ，每项最严重链的误差/界限比在 1.12 至 36238.48 之间。quasi-DEER 的 40 份候选均满足保存的局部归一化残差不超过 1，不能据此推出全路径已达标。两份顺序失败也表明，这不是并行求解独有的数值现象。该补查重放被排除的确定递推，不新增采样或放宽标准；逐链数值和所有原失败数组保留。

4.2 H1 四函数差的配对伴随分析

为确定路径超限在推断函数上的表现，将原 42 项失败与同设备、预算及实际输入的另一 MALA 执行方式配对，去重后得到 80 项（42 失败、38 有效），覆盖 13 个原输入标签。使用已保存的实际初值、噪声及接受随机数，独立 NumPy 重放共 1130496 次转移。它是浮点参照，不是数学精确路径；设备、预算和执行器副本不增加独立重复数。

在原参数尺度分别计算 $v/3$ 、 $\tanh(v/3)$ 、 $\mathbf{1}(x_1 > 0)$ 和 $\cos(x_1 e^{-v/2})$ 。对全路径及剔除原 512 步后的保留段，逐链与等长四链合并报告最大绝对差、均方根差、平均绝对

差、有符号均值差和事件失配。参数映射复算与保存输出一致；独立接受事件和符号函数失配均为 0，3200 行函数汇总未出现非有限值。

函数	最大逐点绝对差	最大合并均值差	最大单链均值差
$v/3$	1.910×10^{-3}	1.078×10^{-7}	4.350×10^{-7}
$\tanh(v/3)$	1.452×10^{-3}	4.690×10^{-8}	1.904×10^{-7}
$\mathbf{1}(x_1 > 0)$	0	0	0
$\cos(x_1 e^{-v/2})$	3.269×10^{-3}	3.078×10^{-7}	1.232×10^{-6}

表 S10: H1 保留段在全部 80 项中的差异极值。均值差列取绝对值；各列最大值未必来自同一任务。合并指同一任务四条等长链，不是把 80 项混合。完整 RMS、平均绝对差、任务身份及全程结果另列于源表。

连续函数的均值差小于最严重位置的差，提示其影响应按函数和汇总方式评价；平均绝对差与 RMS 仍用于区分局部性和正负抵消。该伴随分析不改变原数值合格标准、不把失败轨迹计入主结果，也不对 80 项作独立重复置信区间。冻结分析身份为 `h1-function-path-companion-v1`。全部差数组独立复算后重建 3200 行，恢复检查新增重放 0；完整数据和两幅位置/配对图见仓库的同名分析目录。

4.3 双峰符号事件与初始化

事后伴随分析遍历 M1 全部 432 个任务，读取 412 份有效拟合的 1648 条链及初值、预热或丢弃段、保留段。穿越定义为相邻保存状态的 $\mathbf{1}(\theta_1 > 0)$ 变化，零归入非正侧；不计算 HMC 积分器内部未保存的位置。路径符号与原函数二进制及四链均值逐项核对。20 份失败 NUTS 拟合的部分链不进入完整拟合统计。

384 份有效 MH 拟合没有保存状态的符号穿越；28 份有效 NUTS 拟合中，原重复 5、1024 步 CPU 拟合的第三条链发生一次负侧到正侧穿越，该链保留段正侧比例为 0.4599609375，四链合并比例为 0.614990234375。其余 411 份拟合均无穿越，合并比例恰为 0.5。全部实际初值均为两条负侧、两条正侧，因此零符号平方误差可以由均衡起点维持。

本文将它作为初始化与函数解释的边界，而不是宣称跨峰是每个后验函数估计正确的必要条件。已知权重下的模式分层估计需要自身的条件与不确定性规则。1648 条链、不同工作流和两档预算也不是新增独立重复：原独立单位仍是每目标 24 份四链输入。正文图选择唯一穿越例及相同原重复的 CPU 顺序 RWM，完整逐项结果另附。

目标	有效	数值失败	未分类失败	函数行	$\hat{R} > 1.01$	$\hat{R}$ 未定
G1	415	0	17	1245	240	0
G2	432	0	0	1296	604	0
A1	432	0	0	1296	592	0
L1	414	0	18	1656	444	0
L2	414	0	18	1656	304	414
H1	375	42	15	1500	1387	33
H2	415	0	17	1660	812	0
M1	412	0	20	1648	561	411
W1	432	0	0	3024	56	432

表 S11: 紧凑研究各目标的全部 432 项主任务状态, 以及有效拟合的所选函数诊断。函数行按拟合与函数计数, 不是独立重复; 未分类失败保持原状态。缓存探测不进入这些后验计数。

5 紧凑研究的完整状态与使用成本

5.1 原数组与跨平台统计重建

Mac 独立读取 3888 项主任务与 256 个缓存探测, 全部 4144 项有记录且无读取错误。实际恢复复用全部记录、未新增分析, 42035 个分析资产保持不变。有效 MH 主任务与缓存合计 54448128 次转移的接受事件失配为零; 失败候选另按前节核验, 不混入有效路径分母。

在同一原 Windows 二进制上重算 R 诊断, 14981 函数行的未定位置保留, $\hat{R} = 1.01$ 的分类变化为零; 最大 $\hat{R}$ 差为 4.00×10^{-14} 。逐项比较两平台完整统计, 共 1132 个投影浮点值不同, 最大按 $\max(1, |a|, |b|)$ 缩放的差为 7.51×10^{-15} , 状态、分母及描述性阈值判断无变化。4589 个 bootstrap 数组中 4566 个逐值一致, 其余元素最大差为 6.67×10^{-16} , NaN 位置无变化。原统计和全部差值均保留, 没有加大容差或覆盖原值。

NumPy 的既有 slogdet 除零、溢出和无效值警告原样保留; 冻结变换的实际行列式有限, 先前独立三角因子对数和检查最大差为 2.85×10^{-14} , 本轮重建的参考契约与冻结记录一致。这限定了已检查数值的影响, 未声称已定位底层库警告根因。

5.2 基线失败与诊断实现

432 项 CPU Pyro NUTS 主任务中 327 项有效。1024 步 216/216 有效; 4096 步 105/216 失败 (48.6%), 111 项有效。长预算失败/计划数为 G1 17/24、G2 0/24、A1 0/24、L1 18/24、L2 18/24、H1 15/24、H2 17/24、M1 20/24、W1 0/24。所有原始父进程均保留退出码 0, 但科学任务状态仍为失败; 回执不能只按外层退出码判断成功。失败日志均包含工作进程异常终止信息, 保存的 12 GiB Job 内存上限和峰值计数不足以

单独确认具体根因。失败任务中已完成的 305 条子链保持原件，不并入完整四链后验结果。

48 份有效 A1/G2 长预算拟合的 192 条链均触发 Pyro 1.9.2 旧 ESS 路径的 2145387008 字节分配警告，12288 项逐参数旧 ESS 为空。该实现的相关中间数组随保留长度呈二次增长；R 现代诊断使用另一路径。worker 末次保存后的阶段还包含输出提取及结束处理，不能把其全部时间直接命名为 ESS 耗时。105 项失败的发生阶段仍未确定，原类别与分母保持不变。

5.3 R 前端有限技术计时

一个既有 Poisson 输入包含 32 个观测、2 参数、4 链各 128 步。四工作流、普通/审计两模式及四个技术轮次共 32 个串行新 R 进程，每进程重复同一实际输入两次。torch intra/inter-op 及 BLAS 线程设为 1；运行前确认接收/重建进程已退出，并保存系统负载，但不声称整机独占。首次边界为真实父进程时钟的启动至 R 结果可用通知；持久化在通知之后另记。再次调用复用加载和目标，仍包含完整采样与 R 诊断，不是缓存内核计时。

模式	工作流	R 启动至首次结果/秒	会话内再次调用/秒
普通	RWM / 顺序	1.274 [1.267, 1.282]	0.014 [0.014, 0.015]
普通	RWM / Picard	1.274 [1.270, 1.315]	0.014 [0.013, 0.014]
普通	MALA / 顺序	1.768 [1.691, 5.220]	0.044 [0.043, 0.045]
普通	MALA / quasi-DEER	2.057 [2.023, 2.248]	0.340 [0.335, 0.347]
审计	RWM / 顺序	1.277 [1.276, 1.287]	0.019 [0.019, 0.020]
审计	RWM / Picard	1.281 [1.274, 1.358]	0.019 [0.019, 0.020]
审计	MALA / 顺序	1.712 [1.696, 1.949]	0.054 [0.053, 0.057]
审计	MALA / quasi-DEER	2.041 [2.036, 2.196]	0.350 [0.346, 0.353]

表 S12: M4 CPU 上的 R 前端技术计时。每格四次串行新进程，给出中位数及最小-最大值；同一实际 Poisson 输入，四链各 128 步。首次结果边界含启动和依赖载入，再次调用仍含采样、传输、转换和诊断；完整证据写盘另记。技术重复不增加正式研究的独立样本量，未构造统计区间。

全部 64 次调用保留实际数组、原始计时、现代诊断及独立路径检查，R 返回的 float64 字节与 Python 样本相符。恢复复用 32 个进程，新增执行 0。四次技术重放使用同一随机输入，不作 BCa 或显著性检验，也不增加正式研究的独立重复；短链仍不能作为 Poisson 推断精度证据。

6 历史 CPU 验证与开发证据

历史材料：0.1.0/0.1.1, Mac CPU 开发和核验。本节时态和预算属于该批次，不描述主要实验的完成状态。

软件测试覆盖密度、梯度、Jacobian、约束输出、固定噪声路径、接受事件、拒绝自环、部分窗口、迭代耗尽、非有限目标、内存守卫和共同随机输入回退。错误注入包括遗漏 Jacobian、改变尺度以及改变实际目标造成接受事件失配。协议与文件校验测试还检查重复任务跳过和输出损坏检测。有限测试不能替代一般正确性证明，但提供了可重放的反例检测机制。

冻结 0.1.0 通过 43 项 Python 测试和 R 包检查。审查修订版 0.1.1 进一步通过 58 项 Python 检查、R 包检查及 R 到 BridgeStan 的端到端核验；后者的固定输入样本差为零。CPU 主实验仍对应归档的 0.1.0，新版边界修复不覆盖历史输出。高斯、logistic 与正值模型的 Stan/原生实现交叉核验通过；两个简单高斯目标上，上游固定提交的求解器与独立 MALA 参考的路径差小于 10^{-8} 。这项复现仅检验上游求解器与指定映射的组合，不声称复现原文全部性能实验。

开发探测使用 G1、G2、L1、L2，固定转移数为 256 或 2048，窗口为 16、64、256，每组采用三个实际随机输入数组。192 项任务均完成，最大路径差为 2.17×10^{-9} 。Mac CPU 上的并行执行通常增加了时间；尤其是大数据 logistic 的多次梯度与导数求值成本明显。该探测属于开发资料，最早若干任务与初次 Stan 编译重叠，因此不用于正式速度推断。

小型生成式校准检查从 $\theta \sim N(0, 1)$ 及八个 $y_i \sim N(\theta, 1)$ 生成 12 个独立数据集，每个数据集运行五种工作流。后验具有解析均值 $\sum_i y_i/9$ 和标准差 $1/3$ 。60 次拟合均完成，MALA 的顺序/并行秩直方图相同，RWM 的顺序/并行结果也相同。该重复数下，观察到的区间覆盖不能确证校准；秩抽样的相关性和有限功效须继续检查。正式 SBC 使用另一组 64 个生成数据集和独立种子，避免把已观察的开发样本作为未见验证资料。

在正式 SBC 拟合开始前，另冻结依赖数据的对数似然统计量 $f_y(\theta) = -\frac{1}{2} \sum_i (y_i - \theta)^2$ ，并从同一批保存样本计算其秩和解析后验期望误差。秩每 32 步取一个样本，共 64 个；与真参数处统计量相等的样本单独计数，以独立 Philox 流在并列范围内随机化秩。此伴随分析不改变拟合协议，也不据有限、仍可能相关的秩宣布一般校准通过。

7 历史 Mac CPU 的冻结实验设计

历史材料：0.1.0, Mac 主协议。本节时态和预算属于该批次，不描述主要实验的完成状态。

目标	定义	比较作用
G1	8 维标准高斯	简单几何与执行开销
G2	64 维旋转高斯, 条件数 100	耦合与尺度差异
L1/L2	8 参数 logistic, 样本量 256/4096	似然计算量
H1/H2	9 维漏斗, 中心化/非中心化	相同分布的坐标与预热效应
A1	64 维潜在 AR(1) 高斯后验	高维相关结构
M1	8 维对称双峰高斯混合	跨模式探索压力

表 S13: Mac CPU 主协议的目标库。H1/H2 属于同一模型族; L1/L2 是同类回归的计算量变化。数据由记录的随机规则生成。本研究不把这些变体当作独立应用领域。

7.1 目标族与基线

五种工作流为顺序 MALA、窗口 quasi-DEER MALA、顺序 RWM、Online Picard RWM 和 BlackJAX NUTS。各工作流均采用四链; MH 使用预先固定步长, 前 512 步作为丢弃段, 随后保留 256 或 2048 步。NUTS 单独预热 512 步后保留相同数量, 最大树深为 8。所有初始化固定为零, 步长表、数据、随机种子及运行顺序写入机器可读协议。比较的对象是这些指定工作流, 不能外推为经过全局最优调参的算法排名。

正式协议在独立探测后冻结, 每组 24 次独立重复, 共 1920 项任务。主实验不依据有利结果追加重复或选择模型。原研究计划提出的误差 MCSE 相对阈值 0.1 并未被承诺对每个压力目标满足; 本版冻结有限重复数并完整报告其不确定性, 区间跨阈值时保留为未判定。没有训练自动配置选择器, 也没有将已见模型声明为选择器留出集。

7.2 误差与参考

对预先规定的函数集合 $\mathcal{F}$, 以独立重复评价

$$\hat{E}_a(N) = \max_{f \in \mathcal{F}} \frac{1}{R} \sum_{r=1}^R \left(\hat{\mu}_{a,f}^{(r)}(N) - \mu_f \right)^2 / s_f^2. \quad (3)$$

高斯目标使用标准化首坐标的均值、二阶矩及超过 1 的概率。漏斗目标使用标准化尺度变量、其双曲正切、局部变量的符号事件及条件标准化变量的余弦; 这避免依赖漏斗局部变量的巨大高阶矩。双峰目标同时检查模式占比和连续函数。Logistic 检查前两个参数、截距的 logistic 变换及符号事件。全部函数与尺度在协议中明确, 尺度统一取 1。

解析目标使用真实期望。L1/L2 的参考分别来自四次独立 NUTS 拟合, 每次四链、预热 1024 步、保留 16384 步; 参考种子与正式实验分离。两目标参考均未记录发散, L1 的所检查函数及 L2 的连续函数 split- $\hat{R}$ 接近 1, 非退化函数参考 MCSE 最大约为 7.6×10^{-4} 。原协议计算所选函数的经典 split- $\hat{R}$; 审查后从相同保存样本补充秩正态化/折叠 split- $\hat{R}$ 、bulk ESS 和 tail ESS, 后文单列, 不替换原分析。L2 符号事件在全部参考样本中为零, 其 Rhat 不可判定、参考误差未确定; 不把零经验方差当作已证实

的精度。参考 MCSE 取拟合间估计与批均值估计的较大值；该规则并不排除共同偏差。对这两个目标的结果称为参考平方差，不把它解释为无偏真实 MSE，也不无条件减去参考方差。

不确定性采用独立重复层面的 4000 次重采样，报告逐点 95% 区间；每次重采样先在重复间求平方误差均值，再在预声明函数间取最大值。对可用共同参考另做正态、对角协方差扰动的敏感性传播，同一次扰动在所有重复中共用。它没有估计函数之间的完整参考协方差，不等于联合误差的精确传播；基本重复 bootstrap 区间另行保留。区间不是跨模型、方法和预算的同时置信保证。失败率、成功输出上的条件误差及全部成本分别呈现，有失败时不宣称无条件精度达标。

7.3 计时与资源

本地实验在 M4 Mac mini、16 GB 内存和 JAX CPU 后端上执行，使用 float64、JAX 0.6.2、BlackJAX 1.2.5、NumPy 2.2.6 和 BridgeStan 2.7.0。外层同一时刻运行一个实验任务。目标平台是整台指定机器，未将逻辑 CPU 个数直接解释为独占物理核预算。正式计算期间同机还进行了少量软件核验与文档生成，未实现全程独占空闲系统；保留全部原任务，不依据这种背景活动剔除计时值。

显式同步设备后结束执行计时。记录 JIT 编译、输入、NUTS 预热、执行、传输、独立核验和回退；逐任务墙钟还包含建模和写盘。本文以逐任务墙钟扣除额外计时重放成本、加上后验函数摘要与诊断计算时间，定义完整工作流程时间；建模、原始数组写盘和校验和计算均在该口径内，另保留纯采样接口计时。完成初次执行后对同一编译程序进行两次缓存内重放，作为执行机制计时探测，额外成本单列；它们不是新的统计重复，也不计作增加后验样本。进程导入和一次性软件安装不是单次任务计时的一部分，因此本文不将该口径称为全新进程冷启动。

MH 的步长与窗口作为指定工作流的输入；开发探测属于离线研究费用，单独保留，不在每个正式拟合中重复摊入。NUTS 的逐次适配则包含在预热成本中。因此完整工作流程比较回答的是给定配置的运行成本，尚未覆盖未知新模型上选择 MH 参数所需的成本，不应称为自动调参方案之间的完整费用比较。

CPU 内存为采样 API 期间每 20 ms 记录的进程绝对 RSS 峰值，包含先前驻留分配，未覆盖建模、写盘和子进程；该 CPU 协议不评价 GPU 内存；Windows 另有设备分配器记录。数组空间有事前保守预算检查，数值迭代上限保留。运行没有人为总时长截止。冻结源代码和协议校验和、随机化任务顺序、逐任务原始数组与状态支持中断后恢复；成功与失败结果均保留。

8 历史 CPU 结果与范围

历史材料：0.1.0，Mac 主协议。本节时态和预算属于该批次，不描述主要实验的完成状态。

本机按冻结协议登记了 1920 项正式任务，全部结束，其中 0 项未返回满足输出标准的正常样本。失败计数与原始输出均保留；该总任务数包含配对执行，并非 1920 个独立模型。每个模型、预算及工作流的独立重复数为 24。

正常输出中，独立核验记录的最大数值路径差为 2.36×10^{-8} ，接受事件失配总数为 0。这一陈述以数值核验及当前目标库为边界，不构成一般轨迹或平稳分布证明。

quasi-DEER MALA 的模型—预算组中位缓存执行速度比范围为 0.0192 至 0.174，研究审计工作流速度比范围为 0.0715 至 0.739。速度比定义为同核顺序时间除以并行时间，小于 1 表示并行执行更慢；这里只统计成对有效输出，失败另行报告。

Online Picard RWM 的模型—预算组中位缓存执行速度比范围为 0.0503 至 0.809，研究审计工作流速度比范围为 0.226 至 0.814。速度比定义为同核顺序时间除以并行时间，小于 1 表示并行执行更慢；这里只统计成对有效输出，失败另行报告。




图 S1: 同核成对成本。上、下行分别为每链保留 256 和 2048 步；左列为两次缓存重放时间的中位数之比，右列为含编译、预热/丢弃段和独立核验的工作流时间比。每个点为一个独立重复中的配对比，短线为组中位数；同一轨迹的计时重放不当作统计重复。虚线表示速度比 1。任何缺失配对均在原始任务及失败表中保留。

表中列出较大预算下的函数最大平方误差。L1/L2 采用有限参考，因此相应数值是参考平方差。完整逐函数误差、逐点区间、参考敏感性区间、失败比例区间及两预算结果随机器可读材料交付。不能把表中的最小数值自动解释为确定排名。

目标	顺序 MALA	quasi-DEER	顺序 RWM	Picard	NUTS
G1	0.00199 (0)	0.00199 (0)	0.00542 (0)	0.00542 (0)	0.000531 (0)
G2	0.125 (0)	0.125 (0)	0.164 (0)	0.164 (0)	0.000322 (0)
L1	0.000255 (0)	0.000255 (0)	0.000673 (0)	0.000673 (0)	1.46×10^{-5} (0)
L2	$6.22 \times 10^{-6} \dagger$ (0)	$6.22 \times 10^{-6} \dagger$ (0)	$1.91 \times 10^{-5} \dagger$ (0)	$1.91 \times 10^{-5} \dagger$ (0)	$2.28 \times 10^{-7} \dagger$ (0)
H1	0.138 (0)	0.138 (0)	0.131 (0)	0.131 (0)	0.112 (0)
H2	0.0215 (0)	0.0215 (0)	0.0376 (0)	0.0376 (0)	6.11×10^{-5} (0)
A1	0.00803 (0)	0.00803 (0)	0.856 (0)	0.856 (0)	0.000665 (0)
M1	0.252 (0)	0.252 (0)	0.359 (0)	0.359 (0)	0.296 (0)

表 S14: 每链保留 2048 步时的最大函数平方误差/参考平方差。括号内为该组 24 次重复中的输出失败数；有失败时，误差仅描述成功输出。误差不包含失败的假定损失，不代表无条件达标。 $\dagger$ 表示参考精度未确定，该行仅展示参考平方差，不能判断全函数精度达标。

按前述工作流口径汇总，正式尝试合计耗时 5080.9 秒，其中失败任务耗时 0.0 秒。另有缓存计时重放开销 5711.5 秒，完整保留但不重复计入单次工作流成本。逐组成本及全部失败分母另存分析结果。

NUTS 在 46 个已返回有限样本的任务中记录到发散，总计 2358 个保留转移的发散事件。发散与数值输出失败分别呈现，不能因为数组有限而删除这一诊断。多峰和漏斗目标上的误差须结合模式占比及尺度函数理解。

NUTS 另有 6861 个保留转移达到 255 个积分步的设定上限；积分步数及逐次适配参数随原始记录保存。

采样接口期间记录的逐任务进程 RSS 峰值范围为 244.3 至 549.0 MiB；它包含进程已驻留内存，只覆盖接口调用阶段，不能解释为每种算法的独占增量内存或整项任务的严格峰值。

quasi-DEER 的模型—预算组中，单个输出转移对应的前向转移映射求值次数中位数范围为 14.58 至 66.15，顺序 MH 为 1。

Online Picard 的模型—预算组中，单个输出转移对应的前向转移映射求值次数中位数范围为 2.00 至 21.38，顺序 MH 为 1。

这些程序层面的映射调用计数包含丢弃段和拒绝自环，尚不包含独立审计；它们不是浮点运算量或密度/梯度调用次数。quasi-DEER 的 JVP 另存，因此不能仅据调用数精确分解运行瓶颈。

mala/sequential 在较长预算、 $\epsilon = 0.1$ 下的逐点判断为：区间低于阈值 2 个目标，区间高于阈值 4 个，跨阈值 1 个，参考或输出条件不足 1 个。




图 S2: 固定采样计划的误差—成本关系。横轴为成功输出条件下的 workflow 时间中位数, 全部尝试和失败成本另表保存。每条线连接同一指定工作流的两个预算点, 不表示中间预算已被测量。蓝色为 MALA、橙色为 RWM、灰色为 NUTS; 实线/圆或方形为顺序 MH, 虚线/叉号为相应时间执行器, 三角形为 NUTS。误差取预声明函数中最大的重复平均平方误差; L1/L2 为有限参考平方差。线段区间为逐点 95% 重复重采样区间, 有限参考的共同误差敏感性另行传播; 传播采用正态对角协方差工作假设, 非同时保证。星号表示参考精度未确定, 该面板仅供探索性平方差比较。面板标题列出该模型全部正式任务中的输出失败数, 失败组的误差为条件结果。点虚线标出 0.01 作为预声明误差阈值。

mala/quasi_deer 在较长预算、 $\epsilon = 0.1$ 下的逐点判断为：区间低于阈值 2 个目标，区间高于阈值 4 个，跨阈值 1 个，参考或输出条件不足 1 个。

rwm/sequential 在较长预算、 $\epsilon = 0.1$ 下的逐点判断为：区间低于阈值 2 个目标，区间高于阈值 5 个，跨阈值 0 个，参考或输出条件不足 1 个。

rwm/online_picard 在较长预算、 $\epsilon = 0.1$ 下的逐点判断为：区间低于阈值 2 个目标，区间高于阈值 5 个，跨阈值 0 个，参考或输出条件不足 1 个。

nuts/sequential 在较长预算、 $\epsilon = 0.1$ 下的逐点判断为：区间低于阈值 5 个目标，区间高于阈值 2 个，跨阈值 0 个，参考或输出条件不足 1 个。

这些判断仅对应两个已测量预算中的较长预算，不构成同时置信结论，也不提供单次运行可观测的停止规则或精确的达标时间。

正式生成式检查完成 64 个新数据集、五种工作流，共 320 次拟合，其中 0 次输出失败。90% 后验区间的覆盖估计及其二项区间按数据集作为独立单位报告；保留所有秩与原始样本。抽稀秩仍可能相关，这一检查不提供一般 SBC 一致性证明。

mala/sequential: 覆盖率 0.844, 95% 二项区间 [0.731, 0.922]。

mala/quasi_deer: 覆盖率 0.844, 95% 二项区间 [0.731, 0.922]。

rwm/sequential: 覆盖率 0.828, 95% 二项区间 [0.713, 0.911]。

rwm/online_picard: 覆盖率 0.828, 95% 二项区间 [0.713, 0.911]。

nuts/sequential: 覆盖率 0.828, 95% 二项区间 [0.713, 0.911]。

正式生成式检查另记录到 0 个保留转移的发散事件，涉及 0 次拟合；该诊断与输出失败分开保存。

本次覆盖率点估计均低于名义 90%，而相应二项区间均包含 90%。这一有限重复结果既不能证明完全校准，也不应被改写为已确证系统性覆盖不足。

对数似然测试量也完成 320 次拟合的伴随分析，共记录 0 个秩并列。逐方法秩直方图、抽稀后相关性解析期望误差随原始数据交付；这些描述性诊断不构成统一性检验或正确性证书。

L2 的参考符号事件在 262144 个相关样本中均为零，Rhat 对该函数不可判定，不能把零经验方差当作事件概率已被精确确定。因此保留原函数集合，并将 L2 全函数精度判定标记为未确定。没有通过删除该函数得到达标结论。

上述结果来自历史 Mac CPU 协议，不包含后续 Windows 实验；原生 Windows 实现及其独立协议的实测结果在后文另行报告。

9 审查后的伴随分析与 CPU 机制实验

历史材料：0.1.1, Mac 修订与独立机制协议。本节时态和预算属于该批次，不描述主要实验的完成状态。

9.1 版本与扩展验证

CPU 主实验保留 0.1.0 源代码和原协议；0.1.1 增加约束输出检查、未窗口有效步掩码、错误及失败记录，并修复 R 单元数组。变换检查和掩码可能影响计时，不能用旧性能代表新版。审查后对 8 目标、5 工作流各取原较短预算的第一个重复，旧/新源码分别执行；MH 复用保存的实际随机数组，NUTS 复用锁定随机流。40 组均返回有效输出，最大路径差为 1.99×10^{-13} ，接受事件零失配。这是有限数值对照，不是性能等价或边界正确性证明。

新增 Poisson 回归示例无需改动内核，公开模型对象分别实现 JAX 密度与独立 NumPy 密度/解析梯度，先验证坐标和导数，再比较固定输入的四种 MH 工作流。密度与梯度最大差约 2.84×10^{-14} ；MALA 和 RWM 配对最大路径差分别为 7.90×10^{-11} 和 3.61×10^{-16} ，接受事件无失配。示例旨在说明扩展和核验，不作为新性能或后验收敛证据。

9.2 同数据集的解析 SBC 对照

本节为审查后伴随分析，未追溯为原协议预声明检验。64 组真参数和数据已保存，后验为 $N(\sum_j y_j/9, 1/9)$ ，故直接计算解析 90% 区间，无需新增拟合。解析区间覆盖 54/64，点估计 0.84375，95% 二项区间为 [0.731, 0.922]。五种工作流共享同 64 组数据，同核顺序/并行还共享轨迹，因此不能当作五次独立校准证据。

工作流	覆盖数	分歧数	下端点 RMSE	上端点 RMSE	均值 RMSE	标准差 RMSE
顺序 MALA	54	4	0.0179	0.0195	0.0105	0.0063
quasi-DEER	54	4	0.0179	0.0195	0.0105	0.0063
顺序 RWM	53	3	0.0318	0.0267	0.0147	0.0107
Picard	53	3	0.0318	0.0267	0.0147	0.0107
NUTS	53	3	0.0222	0.0190	0.0115	0.0078

表 S15: 同 64 数据集的配对解析对照。RMSE 按数据集计算；分歧指解析与 MCMC 区间对同一真参数的覆盖判断不同，不能只据总体覆盖率相等判定区间相等。

MALA 的分歧数据集编号为 23、32、36、56，RWM 为 26、32、56，NUTS 为 11、26、36（从 0 编号）。例如 MALA 有 2 例解析覆盖而 MCMC 未覆盖、另 2 例相反，抵消后总覆盖数相同。该批解析覆盖本身偏低，与有限生成样本波动的解释相容；端点及后验矩误差仍显示有限链估计差异，不能据此证明无额外采样偏差。

9.3 现代诊断与有限预算误差的对应

从全部 1920 项保存样本及 8 次参考拟合提取每个参数和预声明函数，以 posterior 1.7.0 计算秩正态化/折叠 split- $\hat{R}$ 、bulk ESS 与 tail ESS[10]。每个拟合分别计算，结果

不替换原经典函数诊断；常量链等不可判定值保留为空。表中汇总 NUTS，全 80 组的逐拟合、逐变量诊断随复现材料交付。

目标/ N	发散%	上限%	最大 $\hat{R}$	最小 bulk ESS	最小 tail ESS	函数误差	判据
A1/256	0.00	0.00	1.018	496.4	469.7	0.00243	低于阈值
A1/2048	0.00	0.00	1.002	5576.0	5186.4	0.000665	低于阈值
G1/256	0.00	0.00	1.018	1198.4	461.8	0.00271	低于阈值
G1/2048	0.00	0.00	1.003	11148.1	5316.6	0.000531	低于阈值
G2/256	0.00	0.00	1.015	636.5	448.0	0.00383	低于阈值
G2/2048	0.00	0.00	1.002	5848.5	5429.4	0.000322	低于阈值
H1/256	0.71	2.67	1.745	6.3	8.0	0.154	高于阈值
H1/2048	1.11	3.16	1.273	11.4	5.4	0.112	高于阈值
H2/256	0.00	0.00	1.018	815.5	545.5	0.000595	低于阈值
H2/2048	0.00	0.00	1.002	7125.8	5438.9	6.11e-05	低于阈值
L1/256	0.00	0.00	1.017	358.2	393.2	0.000154	低于阈值
L1/2048	0.00	0.00	1.003	3459.7	4381.6	1.46e-05	低于阈值
L2/256	0.00	0.00	1.019	507.4	532.0	3.52e-06	不可判定
L2/2048	0.00	0.00	1.002	4243.8	5109.4	2.28e-07	不可判定
M1/256	0.00	0.00	1.738	6.2	30.6	0.301	高于阈值
M1/2048	0.00	0.00	1.734	6.1	26.8	0.296	高于阈值

表 S16: NUTS 按模型和保留预算分组的伴随诊断。发散和上限命中以 24 次拟合、各 4 链的全部保留转移为分母； $\hat{R}$ 为参数与拟合中的最大值，ESS 为最小值。函数误差为原预声明最大平方误差/参考平方差，判据对应原逐点 95% 区间与 0.01 阈值，不由诊断阈值重定义。

2358 次发散与 6861 次积分上限命中均来自中心化漏斗 H1：短/长预算分别为 174/2184 次发散及 657/6204 次上限命中。双峰 M1 无发散，却在两个预算下都有约 1.73 的最大参数 $\hat{R}$ ，所选函数误差亦高于阈值。五个目标的长预算函数误差区间低于阈值，与 H1/M1 的探索问题分别成立；L2 参数诊断良好不消除参考符号事件恒零的不确定性。特定函数误差小、无发散和后验全面探索是不同陈述。

9.4 三种成本口径

缓存执行衡量已编译内核；正常推断应包含必要建模、编译、预热、转换及诊断；研究审计另加入独立顺序参考和完整数组、校验和归档。历史时钟未单独测量正常输出与所有建模步骤，故只能以 $T_{\text{API}} - T_{\text{independent}} + T_{\text{diagnostic}}$ 给出内存内正常使用的记账估计，不能冒称重新实测的完整正常工作流。该估计不含未分离的建模、R 转换和持久化费用。

共享审计成本使速度比向 1 靠近，可能掩盖加速或减速；当前缓存与去独立核验的估计口径也均未显示组中位加速，因此负结果不能仅归因于审计。新增机制实验另直接计量 `audit=False` 的建模、采样与基本均值/方差/链间诊断，并单列普通样本输出耗时；它是最小 Python 正常工作流，不包含 R 转换及现代 posterior 诊断，也不是全新进程冷启动。

执行器	缓存执行	正常内存口径估计	研究审计 workflow
quasi-DEER	0.019–0.174	0.038–0.175	0.072–0.739
Picard	0.050–0.809	0.110–0.393	0.226–0.814

表 S17: 历史主实验中, 各模型-预算组的配对速度比中位数范围。三列均为顺序时间/并行时间; 中列是不同包含项的记账敏感性分析, 不与另外两列混称三种完整实测 workflow。

9.5 小型 CPU 机制实验

审查后另冻结 `cpu-mechanism-v1`, 使用 0.1.1, 目标 G1/G2/L1、链数 1/4、窗口 16/64、每链 256 步、两组成对 MH 执行方式和每格 3 个新实际随机数组, 共 72 项任务。沿用主协议的指定核参数, 冻结随机顺序; 没有按速度追加或删除任务。每次至少 7 次缓存计时重放、总观测窗口至少 0.2 秒, 作为技术重复而非独立统计重复。全部 72 项完成; 分段重放与生产程序首链的接受事件无失配。

生产执行另外记录进程 CPU 秒/墙钟秒和 10 毫秒间隔系统利用率。组中位进程占用约为 1.00–2.99 个 CPU 核当量, 测量包含运行返回和监测开销, 不是物理核心绑定, 也不能将 `vmap` 当作指定核心数的证明。固定前驱状态的微基准比较串行映射与向量化映射在同一批状态、噪声上的吞吐; 它没有 MCMC 的递推依赖, 不能将吞吐比直接当作轨迹加速比。

quasi-DEER 的组中位缓存速度比为 0.0145–0.23, 固定状态批量吞吐比为 0.381–1.91; 每转移前向映射数为 12–45.5, 另有 5.5–22.2 次 JVP。

Picard 的组中位缓存速度比为 0.0477–0.732, 固定状态批量吞吐比为 0.244–2.46; 每转移前向映射数为 2–24.5。

这些量显示局部批量求值收益与完整轨迹重复工作之间的差距, 而非证明单一瓶颈。例如 G1、四链 Picard 把窗口从 16 增至 64 时, 首链每轮确认数的组中位数均约 5.57, 前向工作却从 5.50 增至 20.88 次/转移, 缓存速度比由 0.402 降至 0.170。G2、单链 quasi-DEER 的平均每窗口轮数由 11 增至 22.25, 前向工作从 23 增至 45.5 次/转移, 速度比由 0.051 降至 0.027。窗口扩大会增加可批处理宽度, 但确认推进和求解轮数决定有效工作效率; 这些例子是冻结小网格中的观察, 尚未识别正加速的交叉点。

为审查阶段组成, 另将首链实现拆成单独编译的批量求值/JVP、扫描和接受复核, 并记录每轮残差或确认前缀。拆分插入同步及 Python 控制, 改变了融合执行。所得控制及未细分部分比例很高, 不能据此宣称生产程序主要受 Python 控制限制; 它暴露了分段探针的扰动。全部阶段秒数和原始逐轮记录公开, 可用于复查数值过程; 对生产程序的精确 XLA 剖面仍属于局限。三次独立重复及短微基准不足以给出普遍硬件因果结论。




图 S3: 新冻结的 72 项机制任务。每格 3 个实际随机数组，符号为组中位数，细线为最小至最大值；技术计时重复不扩大样本量。蓝色为 quasi-DEER，橙色为 Picard；圆点为窗口 16，方形为 64；横轴 C 为链数。a: 缓存轨迹速度比，1 以上才为加速。b: 固定状态批量吞吐比，1 以上表示批处理有利，但它不是轨迹加速。c: 每个输出转移的前向映射求值数，quasi-DEER 还另有 JVP；拒绝自环计入转移。d: 进程 CPU 秒/墙钟秒，表示观测消费量而非核数配置。

9.6 可移植复现检查

另建锁定依赖的 Python 环境并安装非 editable 轮子，在迁移目录运行完整测试。首次 57 项通过、1 项因漏带上游比较源文件而失败；补齐许可与该源文件后，仅复查失败项并通过，保留初次失败日志。迁移目录的新目标示例也通过。R 包检查日志与显式 `PB_RUN_INTEGRATION=1` 的 3 项集成测试日志分别交付，后者实际执行 15 个断言，不以默认跳过替代通过。

迁移目录从 1920 项主实验、8 次参考拟合和 320 项 SBC 原始证据重建主摘要，逐字节一致。三个归档含全部源代码、协议、原始数组和论文输入；新临时目录解压后，校验、分析、1928 项现代诊断重算、绘图和编译均通过，诊断值排除耗时后逐项一致。检查仍共享 Mac、R 库和编译器，不等同外部团队或异构系统复现。

以下为历史材料：0.2.0.dev1 原生 Windows 首轮，512 项探索实验。

10 原生 Windows 扩展：独立开发版本与新冻结实验

开发分支 `windows-native-dev` 新增 Python 版本 0.2.0.dev1 及 R 版本 0.2.0.9001。明确 torch 目标与独立 NumPy 参考可在不导入 JAX 的条件下运行，基础安装不再强制拉取 JAX。本轮实际环境为 Windows 11、AMD Ryzen 7 9800X3D、NVIDIA RTX 5080 (sm_120)、驱动 616.56、Python 3.12.14、torch 2.13.0+cu130 及 float64。R 4.6.1 通过 reticulate 整批调用并保持 `iteration×chain×variable` 次序。Stan 仍为 CPU 提供方式，未自动翻译；本轮未编译核验原生 Stan。Pyro 1.9.2 的 CPU NUTS 仅作为单独正态目标统计基线，未接入 GPU NUTS。

实现保持相同 MALA/RWM 核约定、硬接受前向、独立参考与实际随机数组。quasi-DEER 使用非重叠窗口和截断 Rademacher 对角 JVP；Picard 使用滑动窗口，多链按最小已确认前缀共同推进，末窗口只处理实际转移。控制采用 torch eager 与 Python 循环，记录主机标量等待，不宣称融合设备内控制。CPU 65 项和 CUDA 63 项测试通过，另有 72 项原始路径比较与 8 个 R 批量核验。这些有限测试不构成一般正确性证明。

试探网格 96 项完成后，在观察正式结果前冻结 `windows-native-v1`。协议包含 8 个目标、128/512 两个预算、每组 4 份独立随机数组、CPU/CUDA 资源和 4 个 MH 工作流，共 512 项，每项 4 链、窗口 16。新身份同时锁定源码、依赖、设备、数据、数组、坐标、函数与失败规则。所有 512 项通过数值输出检查，接受事件对独立 NumPy 参考零失配，最大路径差为 5.212×10^{-10} 。256 对 CPU/CUDA 实际数组比较亦无事件失配，最大无约束及约束差分别为 2.842×10^{-14} 及 5.684×10^{-13} 。未发生回退或终结失败。

资源	quasi-DEER/MALA	Online Picard/RWM
CPU	0.101–0.359	0.774–3.560
CUDA	0.164–0.505	1.097–5.230

表 S18: 同设备、同 torch、同核的 warmed 执行速度比（顺序秒数/时间执行器秒数）：各 16 个模型/预算组中位数的最小至最大值。两次技术重放不增加独立重复数。这不是 GPU 相对 CPU 的速度比，也不是精确达标时间。

数值完成与推断可靠性有明显区别：480/512 次拟合至少有一个有限 rank/folded Rhat 大于 1.01，108 次拟合包含常量变量或函数，其诊断保留为不可判定。最大有限 Rhat 为 4.666，最小有限 bulk/tail ESS 为 4.085/4.205。该 Rhat 计数仅为描述，没有新增事后验收标准。解析目标的逐函数重复 MSE 及区间另行保存；L1/L2 的有限参考未解决，不宣称精度达标。全拒绝或混合不足轨迹没有被删除或重新调参替换。

另以 12 个新生成数据集进行小型 SBC，五个共享数据工作流共 60 次拟合全部完成。同数据解析 90% 区间与五个工作流的覆盖均为 9/12，解析覆盖的 95% 区间为




图 S4: 原生 Windows 配对执行结果; 每组 4 份独立数组, 误差线为重复层面 2000 次 bootstrap 的逐点 95% 区间, 不提供同时置信保证。CUDA Picard 的 16 组中位数大于 1, 其中 15 组区间下限大于 1。A1/RWM 的全部 32 次拟合均拒绝所有提议, 其速度仅反映自环执行, 不能解释为后验探索加速。quasi-DEER 的所有组中位速度比均小于 1; 全部负结果保留。

[0.428,0.945]; 端点、矩和诊断分别保存。共享数据不能计作 60 个独立校准重复。Pyro CPU NUTS 与 MH 不使用固定同轨迹比较,也未纳入本轮正式速度实验。

正式任务记录成本共 1790.220 秒 (含普通执行和技术重放), 现代 R 诊断另计 28.470 秒; 普通 API 包括建模和基本矩; 核验 API 使用已构建模型, 包含独立参考但不含建模和基本矩。建模、写盘与现代诊断分别记录, 这些计时不能混称完整 workflow。最大 CUDA 分配/保留峰值为 97,251,328/115,343,360 字节, 包含已有驻留分配; CPU 仅有数组空间估算, 未测逐拟合 RSS 峰值。主机标量读取累计 88,406 次, 标量等待计时 4.206 秒含设备等待, 并不隔离全部控制开销。试探分析曾把共享数组的配置变化合并为误差区间; 该区间已撤回, 原输出及哈希保留, 正式分析不受影响。本轮结果仅支持指定 Windows 实现和有限预算下的计算证据, 不将 Mac JAX 与 Windows torch 的完整 workflow 差异全部归因于 GPU。

回传后的独立复核。 Mac 端校验归档内 5866 个文件, 使用冻结 NumPy 参考重放 128 条四链配置并核对全部 512 项实际数组; 接受事件仍为零失配, 同设备速度比和逐函数误差可由原始记录重建。复算 512 项正式及 60 项 SBC 的现代诊断时发现十进制读取敏感性: NumPy 读取的参数列与保存数组逐值相同, 但 Mac R 直接读取 CSV 会改变部分接近重复值的末位精度。以小端 float64 二进制传入 R 后, 在绝对及相对 10^{-11} 比较容差下, 正式诊断的数值分歧由 4158 个指标值降至 2 个, SBC 由 31 个降至 0 个。剩余 2 个 Rhat 差异约为 3.46×10^{-4} ; 后续最小复现定位的数值机制见第 10.1 节。480 项 Rhat 偏高和 108 项常量输出的计数保持不变。这是新增的伴随敏感性分析, 保留 Windows 原诊断, 不将数值接近的路径等同于秩诊断逐值可复现。该复核没有重新测量 GPU 性能, 也没有扩大已验证后端范围。

以下为历史材料：Windows 第二轮机制、诊断和水井接口验证。

10.1 收尾阶段新增的诊断与工作量伴随分析

以下分析于 2026 年 10 月 5 日从原始 Windows 记录追加，没有重新采样或更改原冻结协议。二进制输入后剩余的两个 $\hat{R}$ 差异，来自 H2/RWM 顺序、512 步、重复 3 的 CPU 与 CUDA 任务；丢弃 128 步后的 q2 数组逐值相同，故不是两份独立的差异证据。在 Mac R 4.6.0、posterior 1.7.0 中，未折叠分量为 1.1777201954，折叠中位数比精确中点正确舍入值低一个 ULP，约 2.1684×10^{-19} 。固定输入和其余计算，仅替换这个折叠中心，就使 5 个观测的秩改变，折叠 $\hat{R}$ 由 1.4085688369 变为 1.4082223724，后者重现原 Windows 记录。Windows 原生 R 4.6.1/posterior 1.7.0 的实际回执已返回：原生中位数采用正确舍入中点，折叠 $\hat{R}$ 为 1.4082223724，二进制输入和回写相同。这核实了数值机制及跨系统观测，但未证明某个底层数学库是根因。两种 $\hat{R}$ 都远高于 1.01，不改变混合不足判断，也没有用较小值替换原诊断。12KiB 二进制样例、精确有理数中点、两中心对照和两平台回执随分析源码保存。

对 512 项原记录逐轮核算映射、JVP 和确认前缀，全部计数检查通过。在 16 个模型/预算组的中位数中，quasi-DEER 每输出转移有 11.906–29.500 次前向映射和 5.953–14.750 次 JVP；Picard 有 2.000–6.820 次前向映射，每轮沿每链平均确认 4.493–16.000 步。对应 CPU/CUDA 工作量一致，拒绝自环计入输出转移。映射次数不是密度调用数或 FLOPs，JVP 不能当作一次普通映射定价；这些记录尚不能把总减速因果分解到各个组件。

目标	warmed	速度比	接受率	映射/转移	确认前缀/轮
A1		4.088	0.00000	2.000	16.000
G2		4.380	0.02051	2.293	13.838
G1		1.355	0.49121	6.635	4.763
L1		1.442	0.51611	6.236	5.045

表 S19: CUDA Picard、512 步的四个说明性配置；每格 4 份独立数组的中位数。接受率包含丢弃段，分母包括拒绝自环。完整八目标记录另存，未据此筛除任何配置。该表跨目标的几何和求值成本也不同，不能解释为接受率对速度的单独因果效应。

A1 全拒绝时每轮确认整个窗口；G2 的执行加速也伴随很低的接受率。因此执行收益仍须与合理调参后的函数误差共同考察。CUDA 首次执行的标量等待/采样时间比例，quasi-DEER 组中位数范围为 0.970–4.911%，Picard 为 4.476–6.909%；等待含未完成设备工作且没有覆盖全部控制活动，不是独立的主机开销估计。本伴随分析没有混加首次审计与 warmed 重放，也不将两次技术重放算作独立统计重复。上述历史记录不包含窗口/链数干预；独立机制协议的实测结果见第 11.1 节，共同推断比较仍待完成。

11 跨系统核验与后续推断比较的边界

第二轮接收把无约束路径、参数变换与下游诊断分别核对。108 份 MH 保存路径均在原容差内，接受事件失配为 0；但从同一无约束状态在 Mac 重算原尺度输出时，60 份不满足原逐位相等要求，最大绝对差为 8.88×10^{-15} 。这项严格跨系统检查仍记为失败，不能通过事后添加容差改称全部通过。Windows 同机核验与 Mac 跨系统重算回答不同问题。

CPU Pyro NUTS 在 9 个目标上的串行/四进程技术对照中，54 组保存数组逐字节相同。对收到的 18 份原二进制重新计算 R 诊断，有限 $\hat{R}$ 与 tail ESS 一致，bulk ESS 最大差约 1.02×10^{-12} ，不可判定位置一致。这不意味着重复计算后验函数也必然逐位相同，更不增加独立统计重复数。原短链的探索不足仍然成立。

实际数组传递同样是复现契约的一部分。第二轮启动时，Windows 重新生成的六份候选输入中，噪声与导数探测数组相同，但对数均匀数组有 82/49152 个元素不同，最大差约 4.44×10^{-16} ，因此原协议拒绝启动机制工作流。随后传递原始封存文件，按原哈希和容差完成了下述测量；原启动失败与候选数组仍保留。相同种子和依赖版本不能替代实际数组校验，核验本身也未确定底层数学库差异的因果来源。

11.1 Windows 有限机制测量

独立机制协议在 G1、G2、L1 上各使用 2 份主随机输入，比较窗口 4/16、链数分配及预先规定的 G2 RWM 步长对照。CPU 与 CUDA 各完成 96 个工作流；每个工作流包括首次审计、3 次交错缓存重放和探针后重放。全部 960 份保存路径通过独立 NumPy 参考核验，接受事件零失配，最大绝对路径差为 3.84×10^{-10} 。技术重放、窗口变体和跨设备副本均不增加独立输入数。

测量使用同一台 Windows 11 计算机的 Ryzen 7 9800X3D 和 RTX 5080，torch 主机线程设为 4，CUDA 使用 float64 并显式同步。桌面显示负载仍存在，不将线程数等同独占物理核心数。表 S20 给出全部配置的描述性比值；它们来自三次缓存 sample 时间中位数之比，既不是完整推断成本比，也不是跨独立重复的置信区间。

设备/执行器	配对数	比值大于 1	全部比值范围
CPU / quasi-DEER	24	0	0.092–0.322
CPU / Picard	36	20	0.612–3.574
CUDA / quasi-DEER	24	0	0.139–0.437
CUDA / Picard	36	32	0.778–4.805

表 S20: 机制协议的同核缓存执行比值：同组顺序时间除以时间执行器时间。全部 120 个时间执行配置均保留；quasi-DEER 对应 MALA，Picard 对应 RWM。每模型仅两份独立输入，配对数不能解释为独立实验数。

quasi-DEER 每个输出转移对应 7.75–22.5 次前向映射及 3.875–11.25 次 JVP; Picard 为 2–7.59375 次前向映射 (图 S5)。这些计数包括拒绝自环, 均高于顺序执行的一次前向映射; 映射与 JVP 不是等价浮点工作量, 不能简单相加。每端 6 个工作流完全零接受, 全部保留。例如 G2/RWM 步长 1.0 的第一份输入, 在窗口 4/16 下可一次确认整个窗口, 同时没有接受移动。因此较长的确认前缀可以由自环产生, 并不表示更有效的后验探索。




图 S5: Windows 机制测量中的重复求值与缓存成本。每点为一个配置与实际输入的组合, 共 120 点, 部分重叠; 颜色区分目标, 点形区分窗口。上下行为 CPU/CUDA, 左右列为 quasi-DEER/Picard。纵轴大于 1 表示指定缓存执行较短; 横轴包括拒绝自环。三次技术重放不扩充独立样本量, 图中没有推断精度或统计区间。操作探针存在重叠, 不用于构造可加的独占耗时分解。

预先规定的等 512 个总输出对照提供了另一种解释边界。在 G2、L1 的两份输入及两个设备上, 16 条各 32 步的顺序链均比单条 512 步、窗口 16 的 Picard 链更快, 后者时间为前者的 4.43–6.92 倍。这 8 个技术对照说明链数分配会改变执行吞吐; 两种分配的轨迹长度、初始化份数及探索能力不同, 不能解释为相同推断精度下的优劣。图示的额外工作量与 quasi-DEER 减速相容, 但不足以唯一归因于 JVP、扫描或主机控制; 固定状态操作探针与生产路径不同, 同步及嵌套操作也使各阶段不能相加还原总时间。

11.2 批次运行与安装的实测范围

另一个 Windows 技术批次完成 27 项主任务和 24 项缓存探测 (96 次调用), 包含最大形状、进程集合管理和终态恢复检查。接收端对保存 MH 数组独立重放, 并核对函数与 R 诊断; 这没有新增正式推断重复。90 条函数诊断中仍有 59 条 $\hat{R} > 1.01$ 及 27 条 tail ESS 不可判定, 不能将运行成功解释为收敛。该批次支持其封存运行器的技术能力; 后继适配版本另经独立原生验收与接收核对, 见第11.3节。

Python 0.2.0.dev2 与 R 0.2.0.9002 候选已在 Windows 新建依赖环境和仓库外完成安装核验, 覆盖 CPU/CUDA MH 和 R 批量入口。默认 R 包检查与显式集成测试分别保存; 成功检查不隐去此前安装和 locale 失败。接收端核对源码、sdist、wheel 与 R 包中 17 个模块, 并从保存 RDS 重建诊断, 没有在 Mac 重新测量 CUDA。该证据不涵盖原生 Windows 的 JAX/Stan 安装、GPU NUTS 或第三方团队的独立复现。

以下为历史材料：有限原生适配验收，正式主要实验开始之前。

11.3 原生适配与独立接收的验证层次

任务执行、证据归档和统计解释分别接受核验。独立冻结的原生适配验收在 G1、G2 和水井 W1 各使用一份实际输入，运行 27 项四链主任务及 24 项缓存探测；G1/W1 每链保留 64 步，G2 保留 16384 步。接受原生进程、故障隔离、恢复和身份拒绝检查后，主任务全部返回数值合格结果，缓存 96 次调用仍无普通后验样本资格。前期句柄及测试环境失败、失败测试尝试与修复记录一并归档，没有将测试重试计为新的科学拟合。

接收端在 Mac 上按完整任务表重读原始证据，对 24 项 MH 主 workflow 及全部缓存调用独立重放 NumPy 递推，接受事件失配均为 0；三项 CPU NUTS 按数组、随机状态、适应记录和子进程证据核对，不作 MH 同路径声明。随后从原始函数二进制重建全部 117 条 R 诊断，按既定跨平台输出条件通过比较；这与早期要求原尺度输出逐位相等的检查是不同契约，没有将此前 60 份严格变换失败改为通过。恢复分析复用 51 项结果，未重新采样或重算诊断，原始文件不变。

数值合格仍不能解释为后验探索充分：本次 117 条函数记录中，83 条有限 $\hat{R}$ 大于 1.01，9 条 $\hat{R}$ 及 27 条 tail ESS 不可判定。这些记录共享每个目标的一份输入，不能据 workflow 或缓存调用数建立正式独立重复区间。逐函数诊断、跨平台末位差、数值库警告及原生故障链见配套接收报告；当前证据支持该固定适配版本的有限运行与接收能力，九目标多预算的正式推断比较仍未冻结或执行。

11.4 外部目标与测量接口

水井案例采用 posteriordb 的 3020 个观测，保留原模型中截距和距离系数的平坦先验，而非用带正态先验的内置 logistic 替代。通过两个不同距离上均出现两种结局的观测，可构造可积的似然上界；本数据后验因而可正规化。Stan、NumPy 和 torch 的密度及导数对照、固定输入轨迹与 R 数组传输已核验，Windows 的 12 项接口 workflow 也已独立重放。这些是目标和软件扩展证据；短链的明显不良诊断仍保留。有限参考样本与数值求积另行核对，未认证的罕见事件概率不能改写成解析真值。该案例已用于开发，不能再作为未见模型族的泛化检验。

后续充分预算比较需要将可用输出和完整成本对应到同一批重复。为此，已实现三种分别记录的测量口径：准备后、显式同步的内核执行；包含进程启动、输入读取、采样、变换、普通输出与 R 诊断的批量 workflow；以及进一步包含独立轨迹参考、资源检查和封存的研究审计调用。后两者为嵌套边界，不能相加。给定核参数和已封存输入的普通 workflow 不包含事先调参、环境安装或最外层 R 前端；这些费用须另列。后续终态核验也独立登记，不因增加检查次数而改变第一次推断的成本。

一次完整四链拟合是重复单位，链、缓存重放和基础设施重试不增加重复数。任何一次实际尝试缺少计时回执时，该任务的完整成本保持未知，已知部分仍保留。对函数

f , 误差和成本坐标使用同一组数值有效且函数估计有限的重复; 其中任何任务缺完整成本, 不能通过删去它来生成横坐标。函数不可计算、参考未确定、数值失败和基础设施中断分别记录。共同可用重复上的成对费用比与误差差也采用同一集合, 避免混合不同条件样本。

上述归并与统计接口已连接有限原生适配批次的实际证据; 完整任务表、缓存资格、跨系统函数诊断及零重算恢复均有接收回执。该方法准备没有追溯替换历史 CPU 或 Windows 首轮的计时与 bootstrap 规则, 也不为尚未执行的正式推断提供结果。

12 首轮 Windows 的 CUDA 配对点




图 S6: 首轮 Windows CUDA 全部配对点, 每行四份原始输入; 黑线为中位数, 虚线为速度比 1。左为 quasi-DEER MALA, 右为 Picard RWM。该历史预算和配置不与紧凑研究混合。

13 首轮 Windows 的 CPU 配对点




图 S7: 首轮 Windows CPU 全部配对输入的缓存速度比。四个点为每格四份实际数组; 黑色短线为中位数, 不作置信区间。两个面板依次对应 quasi-DEER MALA 与 Picard RWM。

参考文献

- [1] Zoltowski D.M., Wu S., Gonzalez X., et al. [Parallelizing MCMC Across the Sequence Length](#). Advances in Neural Information Processing Systems, 2025, 38.
- [2] Grazi S., Zanella G. [Parallel computations for Metropolis Markov chains with Picard maps](#). Biometrika, 2026, 113(2): asag022.
- [3] Carpenter B., Gelman A., Hoffman M.D., et al. [Stan: A Probabilistic Programming Language](#). Journal of Statistical Software, 2017, 76(1): 1–32.
- [4] Roualdes E.A., Ward B., Carpenter B., Seyboldt A., Axen S.D. [BridgeStan: Efficient in-memory access to the methods of a Stan model](#). Journal of Open Source Software, 2023, 8(87):5236.
- [5] Cabezas A., Corenflos A., Lao J., Louf R., et al. [BlackJAX: Composable Bayesian inference in JAX](#). arXiv:2402.10797, 2024.
- [6] Bingham E., Chen J.P., Jankowiak M., et al. [Pyro: Deep Universal Probabilistic Programming](#). Journal of Machine Learning Research, 2019, 20(28):1–6.
- [7] NIMBLE development team. [compareMCMCs: Tools for comparing MCMC efficiency from NIMBLE and other engines](#). 软件作者仓库, 访问于 2026 年 10 月 3 日。
- [8] Kulkarni S., Shah K.D., Arora N., et al. [PPL Bench: Evaluation Framework For Probabilistic Programming Languages](#). arXiv:2010.08886v1, 2020. 软件来源: <https://github.com/facebookresearch/pplbench>。
- [9] Magnusson M., Torgander J., Bürkner P.-C., Zhang L., Carpenter B., Vehtari A. [posteriordb: Testing, Benchmarking and Developing Bayesian Inference Algorithms](#). Proceedings of Machine Learning Research, 2025, 258:1198–1206.
- [10] Stan development team. [posterior: Rhat, bulk ESS and tail ESS documentation](#). 软件文档, 版本 1.7.0。
- [11] Senne R. and contributors. [ParallelMCMC.jl](#). 软件仓库, 提交 7be9c86, 访问于 2026 年 10 月 6 日。
- [12] Sosa S. [BayesForge: Bayesian Inference using numpyro and XLA](#). R 包 0.0.1 参考手册, 访问于 2026 年 10 月 6 日。
- [13] Hoffman M.D., Sountsov P. [Tuning-Free Generalized Hamiltonian Monte Carlo](#). Proceedings of Machine Learning Research, 2022, 151:7799–7813.
- [14] Robnik J., Seljak U. [Faster Parallel MCMC: Metropolis Adjustment Is Best Served Warm](#). Proceedings of Machine Learning Research, 2026, 300:2719–2727.
- [15] Dance H., Glaser P., Orbanz P., Adams R.P. [Efficiently Vectorized MCMC on Modern Accelerators](#). Proceedings of Machine Learning Research, 2025, 267:12436–12458.
- [16] Gonzalez X., Warrington A., Smith J.T.H., Linderman S.W. [Towards Scalable and Stable Parallelization of Nonlinear RNNs](#). arXiv:2407.19115v3, 2025 (初版 2024)。

- [17] Vehtari A., Gelman A., Simpson D., Carpenter B., Bürkner P.-C. [Rank-Normalization, Folding, and Localization: An Improved R-hat for Assessing Convergence of MCMC](#). Bayesian Analysis, 2021, 16(2):667–718.
- [18] Modrák M., Moon A.H., Kim S., et al. [Simulation-Based Calibration Checking for Bayesian Computation: The Choice of Test Quantities Shapes Sensitivity](#). Bayesian Analysis, 2025, 20(2):461–488. DOI:10.1214/23-BA1404.
- [19] Owen A.B. [Monte Carlo theory, methods and examples](#). 2013, Chapter 9: Importance sampling. 在线书稿。
- [20] National Institute of Standards and Technology. [Digital Library of Mathematical Functions, Section 3.5: Quadrature](#). Equations 3.5.6, 3.5.19–3.5.21, 访问于 2026 年 10 月 10 日。
- [21] Johansson F. [Arb: Efficient Arbitrary-Precision Midpoint-Radius Interval Arithmetic](#). IEEE Transactions on Computers, 2017, 66(8):1281–1292.