

ParallelBayes：补充方法与完整历史核验记录

中文研究稿：作者与单位待定

2026 年 10 月

本材料保留历史实验的完整数值、诊断、成本口径、跨系统定位和安装记录。各节描述所属批次，不是当前紧凑研究的完成回执；当前正文按研究问题重新组织。原生成段落及其生成器保持不变，旧图表作为历史证据保留。正文新增的可读配对图不改变原始比值或区间。当前正式数据尚待回传。

目录

1	水井后验可正规化的充分条件	2
2	历史 CPU 验证与开发证据	2
3	历史 Mac CPU 的冻结实验设计	3
4	历史 CPU 结果与范围	5
5	审查后的伴随分析与 CPU 机制实验	9
6	原生 Windows 扩展：独立开发版本与新冻结实验	13
7	跨系统核验与后续推断比较的边界	16
8	首轮 Windows 的 CPU 配对点	20

1 水井后验可正规化的充分条件

仅有截距和距离系数两个参数，且平坦先验相对于 $d\alpha d\beta$ 定义。保存数据的 1 基行号 533/531 在 3.25200009346008 米分别对应结局 0/1；2884/190 在 151.065994262695 米对应 0/1。实际协变量为距离除以 100，记两个不同值为 a, b 。设 $g(v) = \sigma(v)\{1 - \sigma(v)\}$ ，选取上述四个似然因子，其余因子均不超过 1，故

$$L(\alpha, \beta) \leq g(\alpha + a\beta)g(\alpha + b\beta).$$

因为 $\int_{\mathbb{R}} g(v) dv = 1$ 且变量变换行列式绝对值为 $|b - a| > 0$,

$$0 < \int_{\mathbb{R}^2} L(\alpha, \beta) d\alpha d\beta \leq \frac{1}{|b - a|} < \infty.$$

因此该二维模型后验可正规化。归档证书使用较松的指数包络及 $4/|b - a|$ 上界，同样有效，原件保留。此证明不认证数值求积参考的有限区域误差或稀有事件精度，也不直接适用于另加回归系数的模型。

2 历史 CPU 验证与开发证据

软件测试覆盖密度、梯度、Jacobian、约束输出、固定噪声路径、接受事件、拒绝自环、部分窗口、迭代耗尽、非有限目标、内存守卫和共同随机输入回退。错误注入包括遗漏 Jacobian、改变尺度以及改变实际目标造成接受事件失配。协议与文件校验测试还检查重复任务跳过和输出损坏检测。有限测试不能替代一般正确性证明，但提供了可重放的反例检测机制。

冻结 0.1.0 通过 43 项 Python 测试和 R 包检查。审查修订版 0.1.1 进一步通过 58 项 Python 检查、R 包检查及 R 到 BridgeStan 的端到端核验；后者的固定输入样本差为零。CPU 主实验仍对应归档的 0.1.0，新版边界修复不覆盖历史输出。高斯、logistic 与正值模型的 Stan/原生实现交叉核验通过；两个简单高斯目标上，上游固定提交的求解器与独立 MALA 参考的路径差小于 10^{-8} 。这项复现仅检验上游求解器与指定映射的组合，不声称复现原文全部性能实验。

开发探测使用 G1、G2、L1、L2，固定转移数为 256 或 2048，窗口为 16、64、256，每组采用三个实际随机输入数组。192 项任务均完成，最大路径差为 2.17×10^{-9} 。Mac CPU 上的并行执行通常增加了时间；尤其是大数据 logistic 的多次梯度与导数求值成本明显。该探测属于开发资料，最早若干任务与初次 Stan 编译重叠，因此不用于正式速度推断。

小型生成式校准检查从 $\theta \sim N(0, 1)$ 及八个 $y_i \sim N(\theta, 1)$ 生成 12 个独立数据集，每个数据集运行五种工作流。后验具有解析均值 $\sum_i y_i/9$ 和标准差 $1/3$ 。60 次拟合均完成，MALA 的顺序/并行秩直方图相同，RWM 的顺序/并行结果也相同。该重复数下，观察到的区间覆盖不能确证校准；秩抽样的相关性和有限功效须继续检查。正式 SBC 使用另一组 64 个生成数据集和独立种子，避免把已观察的开发样本作为未见验证资料。

在正式 SBC 拟合开始前，另冻结依赖数据的对数似然统计量 $f_y(\theta) = -\frac{1}{2} \sum_i (y_i - \theta)^2$ ，并从同一批保存样本计算其秩和解析后验期望误差。秩每 32 步取一个样本，共 64 个；与真参数处统计量相等的样本单独计数，以独立 Philox 流在并列范围内随机化秩。此伴随分析不改变拟合协议，也不据有限、仍可能相关的秩宣布一般校准通过。

3 历史 Mac CPU 的冻结实验设计

3.1 目标族与基线

目标	定义	比较作用
G1	8 维标准高斯	简单几何与执行开销
G2	64 维旋转高斯，条件数 100	耦合与尺度差异
L1/L2	8 参数 logistic，样本量 256/4096	似然计算量
H1/H2	9 维漏斗，中心化/非中心化	相同分布的坐标与预热效应
A1	64 维潜在 AR(1) 高斯后验	高维相关结构
M1	8 维对称双峰高斯混合	跨模式探索压力

表 1: Mac CPU 主协议的目标库。H1/H2 属于同一模型族；L1/L2 是同类回归的计算量变化。数据由记录的随机规则生成。本研究不把这些变体当作独立应用领域。

五种工作流为顺序 MALA、窗口 quasi-DEER MALA、顺序 RWM、Online Picard RWM 和 BlackJAX NUTS。各工作流均采用四链；MH 使用预先固定步长，前 512 步作为丢弃段，随后保留 256 或 2048 步。NUTS 单独预热 512 步后保留相同数量，最大树深为 8。所有初始化固定为零，步长表、数据、随机种子及运行顺序写入机器可读协议。比较的对象是这些指定工作流，不能外推为经过全局最优调参的算法排名。

正式协议在独立探测后冻结，每组 24 次独立重复，共 1920 项任务。主实验不依据有利结果追加重复或选择模型。原研究计划提出的误差 MCSE 相对阈值 0.1 并未被承诺对每个压力目标满足；本版冻结有限重复数并完整报告其不确定性，区间跨阈值时保留为未判定。没有训练自动配置选择器，也没有将已见模型声明为选择器留出集。

3.2 误差与参考

对预先规定的函数集合 $\mathcal{F}$ ，以独立重复评价

$$\hat{E}_a(N) = \max_{f \in \mathcal{F}} \frac{1}{R} \sum_{r=1}^R \left(\hat{\mu}_{a,f}^{(r)}(N) - \mu_f \right)^2 / s_f^2. \quad (1)$$

高斯目标使用标准化首坐标的均值、二阶矩及超过 1 的概率。漏斗目标使用标准化尺度变量、其双曲正切、局部变量的符号事件及条件标准化变量的余弦；这避免依赖漏斗局

部变量的巨大高阶矩。双峰目标同时检查模式占比和连续函数。Logistic 检查前两个参数、截距的 logistic 变换及符号事件。全部函数与尺度在协议中明确，尺度统一取 1。

解析目标使用真实期望。L1/L2 的参考分别来自四次独立 NUTS 拟合，每次四链、预热 1024 步、保留 16384 步；参考种子与正式实验分离。两目标参考均未记录发散，L1 的所检查函数及 L2 的连续函数 $\text{split-}\hat{R}$ 接近 1，非退化函数参考 MCSE 最大约为 7.6×10^{-4} 。原协议计算所选函数的经典 $\text{split-}\hat{R}$ ；审查后从相同保存样本补充秩正态化/折叠 $\text{split-}\hat{R}$ 、bulk ESS 和 tail ESS，后文单列，不替换原分析。L2 符号事件在全部参考样本中为零，其 Rhat 不可判定、参考误差未确定；不把零经验方差当作已证实的精度。参考 MCSE 取拟合间估计与批均值估计的较大值；该规则并不排除共同偏差。对这两个目标的结果称为参考平方差，不把它解释为无偏真实 MSE，也不无条件减去参考方差。

不确定性采用独立重复层面的 4000 次重采样，报告逐点 95% 区间；每次重采样先在重复间求平方误差均值，再在预声明函数间取最大值。对可用共同参考另做正态、对角协方差扰动的敏感性传播，同一次扰动在所有重复中共用。它没有估计函数之间的完整参考协方差，不等于联合误差的精确传播；基本重复 bootstrap 区间另行保留。区间不是跨模型、方法和预算的同时置信保证。失败率、成功输出上的条件误差及全部成本分别呈现，有失败时不宣称无条件精度达标。

3.3 计时与资源

本地实验在 M4 Mac mini、16 GB 内存和 JAX CPU 后端上执行，使用 float64、JAX 0.6.2、BlackJAX 1.2.5、NumPy 2.2.6 和 BridgeStan 2.7.0。外层同一时刻运行一个实验任务。目标平台是整台指定机器，未将逻辑 CPU 个数直接解释为独占物理核预算。正式计算期间同机还进行了少量软件核验与文档生成，未实现全程独占空闲系统；保留全部原任务，不依据这种背景活动剔除计时值。

显式同步设备后结束执行计时。记录 JIT 编译、输入、NUTS 预热、执行、传输、独立核验和回退；逐任务墙钟还包含建模和写盘。本文以逐任务墙钟扣除额外计时重放成本、加上后验函数摘要与诊断计算时间，定义完整工作流程时间；建模、原始数组写盘和校验和计算均在该口径内，另保留纯采样接口计时。完成初次执行后对同一编译程序进行两次缓存内重放，作为执行机制计时探测，额外成本单列；它们不是新的统计重复，也不计作增加后验样本。进程导入和一次性软件安装不是单次任务计时的一部分，因此本文不将该口径称为全新进程冷启动。

MH 的步长与窗口作为指定工作流的输入；开发探测属于离线研究费用，单独保留，不在每个正式拟合中重复摊入。NUTS 的逐次适配则包含在预热成本中。因此完整工作流程比较回答的是给定配置的运行成本，尚未覆盖未知新模型上选择 MH 参数所需的成本，不应称为自动调参方案之间的完整费用比较。

CPU 内存为采样 API 期间每 20 ms 记录的进程绝对 RSS 峰值，包含先前驻留分配，未覆盖建模、写盘和子进程；该 CPU 协议不评价 GPU 内存；Windows 另有设备

分配器记录。数组空间有事前保守预算检查，数值迭代上限保留。运行没有人为总时长截止。冻结源代码和协议校验和、随机化任务顺序、逐任务原始数组与状态支持中断后恢复；成功与失败结果均保留。

4 历史 CPU 结果与范围

本机按冻结协议登记了 1920 项正式任务，全部结束，其中 0 项未返回满足输出标准的正常样本。失败计数与原始输出均保留；该总任务数包含配对执行，并非 1920 个独立模型。每个模型、预算及工作流的独立重复数为 24。

正常输出中，独立核验记录的最大数值路径差为 2.36×10^{-8} ，接受事件失配总数为 0。这一陈述以数值核验及当前目标库为边界，不构成一般轨迹或平稳分布证明。

quasi-DEER MALA 的模型—预算组中位缓存执行速度比范围为 0.0192 至 0.174，研究审计工作流速度比范围为 0.0715 至 0.739。速度比定义为同核顺序时间除以并行时间，小于 1 表示并行执行更慢；这里只统计成对有效输出，失败另行报告。

Online Picard RWM 的模型—预算组中位缓存执行速度比范围为 0.0503 至 0.809，研究审计工作流速度比范围为 0.226 至 0.814。速度比定义为同核顺序时间除以并行时间，小于 1 表示并行执行更慢；这里只统计成对有效输出，失败另行报告。

表中列出较大预算下的函数最大平方误差。L1/L2 采用有限参考，因此相应数值是参考平方差。完整逐函数误差、逐点区间、参考敏感性区间、失败比例区间及两预算结果随机器可读材料交付。不能把表中的最小数值自动解释为确定排名。

目标	顺序 MALA	quasi-DEER	顺序 RWM	Picard	NUTS
G1	0.00199 (0)	0.00199 (0)	0.00542 (0)	0.00542 (0)	0.000531 (0)
G2	0.125 (0)	0.125 (0)	0.164 (0)	0.164 (0)	0.000322 (0)
L1	0.000255 (0)	0.000255 (0)	0.000673 (0)	0.000673 (0)	1.46×10^{-5} (0)
L2	$6.22 \times 10^{-6} \dagger$ (0)	$6.22 \times 10^{-6} \dagger$ (0)	$1.91 \times 10^{-5} \dagger$ (0)	$1.91 \times 10^{-5} \dagger$ (0)	$2.28 \times 10^{-7} \dagger$ (0)
H1	0.138 (0)	0.138 (0)	0.131 (0)	0.131 (0)	0.112 (0)
H2	0.0215 (0)	0.0215 (0)	0.0376 (0)	0.0376 (0)	6.11×10^{-5} (0)
A1	0.00803 (0)	0.00803 (0)	0.856 (0)	0.856 (0)	0.000665 (0)
M1	0.252 (0)	0.252 (0)	0.359 (0)	0.359 (0)	0.296 (0)

表 2: 每链保留 2048 步时的最大函数平方误差/参考平方差。括号内为该组 24 次重复中的输出失败数；有失败时，误差仅描述成功输出。误差不包含失败的假定损失，不代表无条件达标。 $\dagger$ 表示参考精度未确定，该行仅展示参考平方差，不能判断全函数精度达标。

按前述工作流口径汇总，正式尝试合计耗时 5080.9 秒，其中失败任务耗时 0.0 秒。另有缓存计时重放开销 5711.5 秒，完整保留但不重复计入单次工作流成本。逐组成本及全部失败分母另存分析结果。




图 1: 同核成对成本。上、下行分别为每链保留 256 和 2048 步；左列为两次缓存重放时间的中位数之比，右列为含编译、预热/丢弃段和独立核验的工作流时间比。每个点为一个独立重复中的配对比，短线为组中位数；同一轨迹的计时重放不当作统计重复。虚线表示速度比 1。任何缺失配对均在原始任务及失败表中保留。

NUTS 在 46 个已返回有限样本的任务中记录到发散，总计 2358 个保留转移的发散事件。发散与数值输出失败分别呈现，不能因为数组有限而删除这一诊断。多峰和漏斗目标上的误差须结合模式占比及尺度函数理解。

NUTS 另有 6861 个保留转移达到 255 个积分步的设定上限；积分步数及逐次适配参数随原始记录保存。

采样接口期间记录的逐任务进程 RSS 峰值范围为 244.3 至 549.0 MiB；它包含进程已驻留内存，只覆盖接口调用阶段，不能解释为每种算法的独占增量内存或整项任务的严格峰值。

quasi-DEER 的模型—预算组中，单个输出转移对应的前向转移映射求值次数中位数范围为 14.58 至 66.15，顺序 MH 为 1。

Online Picard 的模型—预算组中，单个输出转移对应的前向转移映射求值次数中位数范围为 2.00 至 21.38，顺序 MH 为 1。

这些程序层面的映射调用计数包含丢弃段和拒绝自环，尚不包含独立审计；它们不是浮点运算量或密度/梯度调用次数。quasi-DEER 的 JVP 另存，因此不能仅据调用数精确分解运行瓶颈。

mala/sequential 在较长预算、 $\epsilon = 0.1$ 下的逐点判断为：区间低于阈值 2 个目标，区间高于阈值 4 个，跨阈值 1 个，参考或输出条件不足 1 个。

mala/quasi_deer 在较长预算、 $\epsilon = 0.1$ 下的逐点判断为：区间低于阈值 2 个目标，区间高于阈值 4 个，跨阈值 1 个，参考或输出条件不足 1 个。

rwm/sequential 在较长预算、 $\epsilon = 0.1$ 下的逐点判断为：区间低于阈值 2 个目标，区间高于阈值 5 个，跨阈值 0 个，参考或输出条件不足 1 个。

rwm/online_picard 在较长预算、 $\epsilon = 0.1$ 下的逐点判断为：区间低于阈值 2 个目标，区间高于阈值 5 个，跨阈值 0 个，参考或输出条件不足 1 个。

nuts/sequential 在较长预算、 $\epsilon = 0.1$ 下的逐点判断为：区间低于阈值 5 个目标，区间高于阈值 2 个，跨阈值 0 个，参考或输出条件不足 1 个。

这些判断仅对应两个已测量预算中的较长预算，不构成同时置信结论，也不提供单次运行可观测的停止规则或精确的达标时间。

正式生成式检查完成 64 个新数据集、五种工作流，共 320 次拟合，其中 0 次输出失败。90% 后验区间的覆盖估计及其二项区间按数据集作为独立单位报告；保留所有秩与原始样本。抽稀秩仍可能相关，这一检查不提供一般 SBC 一致性证明。

mala/sequential: 覆盖率 0.844, 95% 二项区间 [0.731, 0.922]。

mala/quasi_deer: 覆盖率 0.844, 95% 二项区间 [0.731, 0.922]。

rwm/sequential: 覆盖率 0.828, 95% 二项区间 [0.713, 0.911]。

rwm/online_picard: 覆盖率 0.828, 95% 二项区间 [0.713, 0.911]。

nuts/sequential: 覆盖率 0.828, 95% 二项区间 [0.713, 0.911]。

正式生成式检查另记录到 0 个保留转移的发散事件，涉及 0 次拟合；该诊断与输出失败分开保存。




图 2: 固定采样计划的误差—成本关系。横轴为成功输出条件下的 workflow 时间中位数, 全部尝试和失败成本另表保存。每条线连接同一指定工作流的一个预算点, 不表示中间预算已被测量。蓝色为 MALA、橙色为 RWM、灰色为 NUTS; 实线/圆或方形为顺序 MH, 虚线/叉号为相应时间执行器, 三角形为 NUTS。误差取预声明函数中最大的重复平均平方误差; L1/L2 为有限参考平方差。线段区间为逐点 95% 重复重采样区间, 有限参考的共同误差敏感性另行传播; 传播采用正态对角协方差工作假设, 非同时保证。星号表示参考精度未确定, 该面板仅供探索性平方差比较。面板标题列出该模型全部正式任务中的输出失败数, 失败组的误差为条件结果。点虚线标出 0.01 作为预声明误差阈值。

本次覆盖率点估计均低于名义 90%，而相应二项区间均包含 90%。这一有限重复结果既不能证明完全校准，也不应被改写为已确证系统性覆盖不足。

对数似然测试量也完成 320 次拟合的伴随分析，共记录 0 个秩并列。逐方法秩直方图、抽稀后相关性及解析期望误差随原始数据交付；这些描述性诊断不构成统一性检验或正确性证书。

L2 的参考符号事件在 262144 个相关样本中均为零，Rhat 对该函数不可判定，不能把零经验方差当作事件概率已被精确确定。因此保留原函数集合，并将 L2 全函数精度判定标记为未确定。没有通过删除该函数得到达标结论。

上述结果来自历史 Mac CPU 协议，不包含后续 Windows 实验；原生 Windows 实现及其独立协议的实测结果在后文另行报告。

5 审查后的伴随分析与 CPU 机制实验

5.1 版本与扩展验证

CPU 主实验保留 0.1.0 源代码和原协议；0.1.1 增加约束输出检查、未窗口有效步掩码、错误及失败记录，并修复 R 单元元素数组。变换检查和掩码可能影响计时，不能用旧性能代表新版。审查后对 8 目标、5 工作流各取原较短预算的第一个重复，旧/新源码分别执行；MH 复用保存的实际随机数组，NUTS 复用锁定随机流。40 组均返回有效输出，最大路径差为 1.99×10^{-13} ，接受事件零失配。这是有限数值对照，不是性能等价或边界正确性证明。

新增 Poisson 回归示例无需改动内核，公开模型对象分别实现 JAX 密度与独立 NumPy 密度/解析梯度，先验证坐标和导数，再比较固定输入的四组 MH 工作流。密度与梯度最大差约 2.84×10^{-14} ；MALA 和 RWM 配对最大路径差分别为 7.90×10^{-11} 和 3.61×10^{-16} ，接受事件无失配。示例旨在说明扩展和核验，不作为新性能或后验收敛证据。

5.2 同数据集的解析 SBC 对照

本节为审查后伴随分析，未追溯为原协议预声明检验。64 组真参数和数据已保存，后验为 $N(\sum_j y_j/9, 1/9)$ ，故直接计算解析 90% 区间，无需新增拟合。解析区间覆盖 54/64，点估计 0.84375，95% 二项区间为 [0.731, 0.922]。五种工作流共享同 64 组数据，同核顺序/并行还共享轨迹，因此不能当作五次独立校准证据。

MALA 的分歧数据集编号为 23、32、36、56，RWM 为 26、32、56，NUTS 为 11、26、36（从 0 编号）。例如 MALA 有 2 例解析覆盖而 MCMC 未覆盖、另 2 例相反，抵消后总覆盖数相同。该批解析覆盖本身偏低，与有限生成样本波动的解释相容；端点及后验矩误差仍显示有限链估计差异，不能据此证明无额外采样偏差。

工作流	覆盖数	分歧数	下端点 RMSE	上端点 RMSE	均值 RMSE	标准差 RMSE
顺序 MALA	54	4	0.0179	0.0195	0.0105	0.0063
quasi-DEER	54	4	0.0179	0.0195	0.0105	0.0063
顺序 RWM	53	3	0.0318	0.0267	0.0147	0.0107
Picard	53	3	0.0318	0.0267	0.0147	0.0107
NUTS	53	3	0.0222	0.0190	0.0115	0.0078

表 3: 同 64 数据集的配对解析对照。RMSE 按数据集计算；分歧指解析与 MCMC 区间对同一真参数的覆盖判断不同，不能只据总体覆盖率相等判定区间相等。

5.3 现代诊断与有限预算误差的对应

从全部 1920 项保存样本及 8 次参考拟合提取每个参数和预声明函数，以 posterior 1.7.0 计算秩正态化/折叠 split- $\hat{R}$ 、bulk ESS 与 tail ESS[10]。每个拟合分别计算，结果不替换原经典函数诊断；常量链等不可判定值保留为空。表中汇总 NUTS，全 80 组的逐拟合、逐变量诊断随复现材料交付。

目标/ N	发散%	上限%	最大 $\hat{R}$	最小 bulk ESS	最小 tail ESS	函数误差	判据
A1/256	0.00	0.00	1.018	496.4	469.7	0.00243	低于阈值
A1/2048	0.00	0.00	1.002	5576.0	5186.4	0.000665	低于阈值
G1/256	0.00	0.00	1.018	1198.4	461.8	0.00271	低于阈值
G1/2048	0.00	0.00	1.003	11148.1	5316.6	0.000531	低于阈值
G2/256	0.00	0.00	1.015	636.5	448.0	0.00383	低于阈值
G2/2048	0.00	0.00	1.002	5848.5	5429.4	0.000322	低于阈值
H1/256	0.71	2.67	1.745	6.3	8.0	0.154	高于阈值
H1/2048	1.11	3.16	1.273	11.4	5.4	0.112	高于阈值
H2/256	0.00	0.00	1.018	815.5	545.5	0.000595	低于阈值
H2/2048	0.00	0.00	1.002	7125.8	5438.9	6.11e-05	低于阈值
L1/256	0.00	0.00	1.017	358.2	393.2	0.000154	低于阈值
L1/2048	0.00	0.00	1.003	3459.7	4381.6	1.46e-05	低于阈值
L2/256	0.00	0.00	1.019	507.4	532.0	3.52e-06	不可判定
L2/2048	0.00	0.00	1.002	4243.8	5109.4	2.28e-07	不可判定
M1/256	0.00	0.00	1.738	6.2	30.6	0.301	高于阈值
M1/2048	0.00	0.00	1.734	6.1	26.8	0.296	高于阈值

表 4: NUTS 按模型和保留预算分组的伴随诊断。发散和上限命中以 24 次拟合、各 4 链的全部保留转移为分母； $\hat{R}$ 为参数与拟合中的最大值，ESS 为最小值。函数误差为原预声明最大平方误差/参考平方差，判据对应原逐点 95% 区间与 0.01 阈值，不由诊断阈值重定义。

2358 次发散与 6861 次积分上限命中均来自中心化漏斗 H1：短/长预算分别为 174/2184 次发散及 657/6204 次上限命中。双峰 M1 无发散，却在两个预算下都有约 1.73 的最大参数 $\hat{R}$ ，所选函数误差亦高于阈值。五个目标的长预算函数误差区间低于阈值，与 H1/M1 的探索问题分别成立；L2 参数诊断良好不消除参考符号事件恒零的不确定性。特定函数误差小、无发散和后验全面探索是不同陈述。

5.4 三种成本口径

缓存执行衡量已编译内核；正常推断应包含必要建模、编译、预热、转换及诊断；研究审计另加入独立顺序参考和完整数组、校验和归档。历史时钟未单独测量正常输出与所有建模步骤，故只能以 $T_{\text{API}} - T_{\text{independent}} + T_{\text{diagnostic}}$ 给出内存内正常使用的记账估计，不能冒称重新实测的完整正常工作流。该估计不含未分离的建模、R 转换和持久化费用。

执行器	缓存执行	正常内存口径估计	研究审计工作流
quasi-DEER	0.019–0.174	0.038–0.175	0.072–0.739
Picard	0.050–0.809	0.110–0.393	0.226–0.814

表 5: 历史主实验中，各模型–预算组的配对速度比中位数范围。三列均为顺序时间/并行时间；中列是不同包含项的记账敏感性分析，不与另外两列混称三种完整实测工作流。

共享审计成本使速度比向 1 靠近，可能掩盖加速或减速；当前缓存与去独立核验的估计口径也均未显示组中位加速，因此负结果不能仅归因于审计。新增机制实验另直接计量 `audit=False` 的建模、采样与基本均值/方差/链间诊断，并单列普通样本输出耗时；它是最小 Python 正常工作流，不包含 R 转换及现代 posterior 诊断，也不是全新进程冷启动。

5.5 小型 CPU 机制实验

审查后另冻结 `cpu-mechanism-v1`，使用 0.1.1，目标 G1/G2/L1、链数 1/4、窗口 16/64、每链 256 步、两组成对 MH 执行方式和每格 3 个新实际随机数组，共 72 项任务。沿用主协议的指定核参数，冻结随机顺序；没有按速度追加或删除任务。每次至少 7 次缓存计时重放、总观测窗口至少 0.2 秒，作为技术重复而非独立统计重复。全部 72 项完成；分段重放与生产程序首链的接受事件无失配。

生产执行另外记录进程 CPU 秒/墙钟秒和 10 毫秒间隔系统利用率。组中位进程占用约为 1.00–2.99 个 CPU 核当量，测量包含运行返回和监测开销，不是物理核心绑定，也不能将 `vmap` 当作指定核心数的证明。固定前驱状态的微基准比较串行映射与向量化映射在同一批状态、噪声上的吞吐；它没有 MCMC 的递推依赖，不能将吞吐比直接当作轨迹加速比。

quasi-DEER 的组中位缓存速度比为 0.0145–0.23，固定状态批量吞吐比为 0.381–1.91；每转移前向映射数为 12–45.5，另有 5.5–22.2 次 JVP。

Picard 的组中位缓存速度比为 0.0477–0.732，固定状态批量吞吐比为 0.244–2.46；每转移前向映射数为 2–24.5。

这些量显示局部批量求值收益与完整轨迹重复工作之间的差距，而非证明单一瓶




图 3: 新冻结的 72 项机制任务。每格 3 个实际随机数组, 符号为组中位数, 细线为最小至最大值; 技术计时重复不扩大样本量。蓝色为 quasi-DEER, 橙色为 Picard; 圆点为窗口 16, 方形为 64; 横轴 C 为链数。a: 缓存轨迹速度比, 1 以上才为加速。b: 固定状态批量吞吐比, 1 以上表示批处理有利, 但它不是轨迹加速。c: 每个输出转移的前向映射求值数, quasi-DEER 还另有 JVP; 拒绝自环计入转移。d: 进程 CPU 秒/墙钟秒, 表示观测消费量而非核数配置。

颈。例如 G1、四链 Picard 把窗口从 16 增至 64 时，首链每轮确认数的组中位数均约 5.57，前向工作却从 5.50 增至 20.88 次/转移，缓存速度比由 0.402 降至 0.170。G2、单链 quasi-DEER 的平均每窗口轮数由 11 增至 22.25，前向工作从 23 增至 45.5 次/转移，速度比由 0.051 降至 0.027。窗口扩大会增加可批处理宽度，但确认推进和求解轮数决定有效工作效率；这些例子是冻结小网格中的观察，尚未识别正加速的交叉点。

为审查阶段组成，另将首链实现拆成单独编译的批量求值/JVP、扫描和接受复核，并记录每轮残差或确认前缀。拆分插入同步及 Python 控制，改变了融合执行。所得控制及未细分部分比例很高，不能据此宣称生产程序主要受 Python 控制限制；它暴露了分段探针的扰动。全部阶段秒数和原始逐轮记录公开，可用于复查数值过程；对生产程序的精确 XLA 剖面仍属于局限。三次独立重复及短微基准不足以给出普遍硬件因果结论。

5.6 可移植复现检查

另建锁定依赖的 Python 环境并安装非 editable 轮子，在迁移目录运行完整测试。首次 57 项通过、1 项因漏带上游比较源文件而失败；补齐许可与该源文件后，仅复查失败项并通过，保留初次失败日志。迁移目录的新目标示例也通过。R 包检查日志与显式 `PB_RUN_INTEGRATION=1` 的 3 项集成测试日志分别交付，后者实际执行 15 个断言，不以默认跳过替代通过。

迁移目录从 1920 项主实验、8 次参考拟合和 320 项 SBC 原始证据重建主摘要，逐字节一致。三个归档含全部源代码、协议、原始数组和论文输入；新临时目录解压后，校验、分析、1928 项现代诊断重算、绘图和编译均通过，诊断值排除耗时后逐项一致。检查仍共享 Mac、R 库和编译器，不等同外部团队或异构系统复现。

6 原生 Windows 扩展：独立开发版本与新冻结实验

开发分支 `windows-native-dev` 新增 Python 版本 0.2.0.dev1 及 R 版本 0.2.0.9001。明确 torch 目标与独立 NumPy 参考可在不导入 JAX 的条件下运行，基础安装不再强制拉取 JAX。本轮实际环境为 Windows 11、AMD Ryzen 7 9800X3D、NVIDIA RTX 5080 (sm_120)、驱动 616.56、Python 3.12.14、torch 2.13.0+cu130 及 float64。R 4.6.1 通过 reticulate 整批调用并保持 `iteration×chain×variable` 次序。Stan 仍为 CPU 提供方式，未自动翻译；本轮未编译核验原生 Stan。Pyro 1.9.2 的 CPU NUTS 仅作为单独正态目标统计基线，未接入 GPU NUTS。

实现保持相同 MALA/RWM 核约定、硬接受前向、独立参考与实际随机数组。quasi-DEER 使用非重叠窗口和截断 Rademacher 对角 JVP；Picard 使用滑动窗口，多链按最小已确认前缀共同推进，末窗口只处理实际转移。控制采用 torch eager 与 Python 循环，记录主机标量等待，不宣称融合设备内控制。CPU 65 项和 CUDA 63 项测试通过，另有 72 项原始路径比较与 8 个 R 批量核验。这些有限测试不构成一般正确性证明。

试探网格 96 项完成后，在观察正式结果前冻结 `windows-native-v1`。协议包含 8 个目标、128/512 两个预算、每组 4 份独立随机数组、CPU/CUDA 资源和 4 个 MH 工作流，共 512 项，每项 4 链、窗口 16。新身份同时锁定源码、依赖、设备、数据、数组、坐标、函数与失败规则。所有 512 项通过数值输出检查，接受事件对独立 NumPy 参考零失配，最大路径差为 5.212×10^{-10} 。256 对 CPU/CUDA 实际数组比较亦无事件失配，最大无约束及约束差分别为 2.842×10^{-14} 及 5.684×10^{-13} 。未发生回退或终结失败。

资源	quasi-DEER/MALA	Online Picard/RWM
CPU	0.101–0.359	0.774–3.560
CUDA	0.164–0.505	1.097–5.230

表 6: 同设备、同 torch、同核的 warmed 执行速度比 (顺序秒数/时间执行器秒数): 各 16 个模型/预算组中位数的最小至最大值。两次技术重放不增加独立重复数。这不是 GPU 相对 CPU 的速度比，也不是精确达标时间。




图 4: 原生 Windows 配对执行结果; 每组 4 份独立数组, 误差线为重复层面 2000 次 bootstrap 的逐点 95% 区间, 不提供同时置信保证。CUDA Picard 的 16 组中位数大于 1, 其中 15 组区间下限大于 1。A1/RWM 的全部 32 次拟合均拒绝所有提议, 其速度仅反映自环执行, 不能解释为后验探索加速。quasi-DEER 的所有组中位速度比均小于 1; 全部负结果保留。

数值完成与推断可靠性有明显区别: 480/512 次拟合至少有一个有限 rank/folded Rhat 大于 1.01, 108 次拟合包含常量变量或函数, 其诊断保留为不可判定。最大有限

Rhat 为 4.666，最小有限 bulk/tail ESS 为 4.085/4.205。该 Rhat 计数仅为描述，没有新增事后验收标准。解析目标的逐函数重复 MSE 及区间另行保存；L1/L2 的有限参考未解决，不宣称精度达标。全拒绝或混合不足轨迹没有被删除或重新调参替换。

另以 12 个新生成数据集进行小型 SBC，五个共享数据工作流共 60 次拟合全部完成。同数据解析 90% 区间与五个工作流的覆盖均为 9/12，解析覆盖的 95% 区间为 [0.428, 0.945]；端点、矩和诊断分别保存。共享数据不能计作 60 个独立校准重复。Pyro CPU NUTS 与 MH 不使用固定同轨迹比较，也未纳入本轮正式速度实验。

正式任务记录成本共 1790.220 秒（含普通执行和技术重放），现代 R 诊断另计 28.470 秒；普通 API 包括建模和基本矩；核验 API 使用已构建模型，包含独立参考但不含建模和基本矩。建模、写盘与现代诊断分别记录，这些计时不能混称完整工作流。最大 CUDA 分配/保留峰值为 97,251,328/115,343,360 字节，包含已有驻留分配；CPU 仅有数组空间估算，未测逐拟合 RSS 峰值。主机标量读取累计 88,406 次，标量等待计时 4.206 秒含设备等待，并不隔离全部控制开销。试探分析曾把共享数组的配置变化合并为误差区间；该区间已撤回，原输出及哈希保留，正式分析不受影响。本轮结果仅支持指定 Windows 实现和有限预算下的计算证据，不将 Mac JAX 与 Windows torch 的完整工作流程差异全部归因于 GPU。

回传后的独立复核。 Mac 端校验归档内 5866 个文件，使用冻结 NumPy 参考重放 128 条四链配置并核对全部 512 项实际数组；接受事件仍为零失配，同设备速度比和逐函数误差可由原始记录重建。复算 512 项正式及 60 项 SBC 的现代诊断时发现十进制读取敏感性：NumPy 读取的参数列与保存数组逐值相同，但 Mac R 直接读取 CSV 会改变部分接近重复值的末位精度。以小端 float64 二进制传入 R 后，在绝对及相对 10^{-11} 比较容差下，正式诊断的数值分歧由 4158 个指标值降至 2 个，SBC 由 31 个降至 0 个。剩余 2 个 Rhat 差异约为 3.46×10^{-4} ；后续最小复现定位的数值机制见第 6.1 节。480 项 Rhat 偏高和 108 项常量输出的计数保持不变。这是新增的伴随敏感性分析，保留 Windows 原诊断，不将数值接近的路径等同于秩诊断逐值可复现。该复核没有重新测量 GPU 性能，也没有扩大已验证后端范围。

6.1 收尾阶段新增的诊断与工作量伴随分析

以下分析于 2026 年 10 月 5 日从原始 Windows 记录追加，没有重新采样或更改原冻结协议。二进制输入后剩余的两个 $\hat{R}$ 差异，来自 H2/RWM 顺序、512 步、重复 3 的 CPU 与 CUDA 任务；丢弃 128 步后的 q2 数组逐值相同，故不是两份独立的差异证据。在 Mac R 4.6.0、posterior 1.7.0 中，未折叠分量为 1.1777201954，折叠中位数比精确中点正确舍入值低一个 ULP，约 2.1684×10^{-19} 。固定输入和其余计算，仅替换这个折叠中心，就使 5 个观测的秩改变，折叠 $\hat{R}$ 由 1.4085688369 变为 1.4082223724，后者重现原 Windows 记录。Windows 原生 R 4.6.1/posterior 1.7.0 的实际回执已返回：原生中位数采用正确舍入中点，折叠 $\hat{R}$ 为 1.4082223724，二进制输入和回写相同。这核实了数

值机制及跨系统观测，但未证明某个底层数学库是根因。两种 $\hat{R}$ 都远高于 1.01，不改变混合不足判断，也没有用较小值替换原诊断。12KiB 二进制样例、精确有理数中点、两中心对照和两平台回执随分析源码保存。

对 512 项原记录逐轮核算映射、JVP 和确认前缀，全部计数检查通过。在 16 个模型/预算组的中位数中，quasi-DEER 每输出转移有 11.906–29.500 次前向映射和 5.953–14.750 次 JVP；Picard 有 2.000–6.820 次前向映射，每轮沿每链平均确认 4.493–16.000 步。对应 CPU/CUDA 工作量一致，拒绝自环计入输出转移。映射次数不是密度调用数或 FLOPs，JVP 不能当作一次普通映射定价；这些记录尚不能把总减速因果分解到各个组件。

目标	warmed	速度比	接受率	映射/转移	确认前缀/轮
A1		4.088	0.00000	2.000	16.000
G2		4.380	0.02051	2.293	13.838
G1		1.355	0.49121	6.635	4.763
L1		1.442	0.51611	6.236	5.045

表 7: CUDA Picard、512 步的四个说明性配置；每格 4 份独立数组的中位数。接受率包含丢弃段，分母包括拒绝自环。完整八目标记录另存，未据此筛除任何配置。该表跨目标的几何和求值成本也不同，不能解释为接受率对速度的单独因果效应。

A1 全拒绝时每轮确认整个窗口；G2 的执行加速也伴随很低的接受率。因此执行收益仍须与合理调参后的函数误差共同考察。CUDA 首次执行的标量等待/采样时间比例，quasi-DEER 组中位数范围为 0.970–4.911%，Picard 为 4.476–6.909%；等待含未完成设备工作且没有覆盖全部控制活动，不是独立的主机开销估计。本伴随分析没有混加首次审计与 warmed 重放，也不将两次技术重放算作独立统计重复。上述历史记录不包含窗口/链数干预；独立机制协议的实测结果见第 7.1 节，共同推断比较仍待完成。

7 跨系统核验与后续推断比较的边界

第二轮接收把无约束路径、参数变换与下游诊断分别核对。108 份 MH 保存路径均在原容差内，接受事件失配为 0；但从同一无约束状态在 Mac 重算原尺度输出时，60 份不满足原逐位相等要求，最大绝对差为 8.88×10^{-15} 。这项严格跨系统检查仍记为失败，不能通过事后添加容差改称全部通过。Windows 同机核验与 Mac 跨系统重算回答不同问题。

CPU Pyro NUTS 在 9 个目标上的串行/四进程技术对照中，54 组保存数组逐字节相同。对收到的 18 份原二进制重新计算 R 诊断，有限 $\hat{R}$ 与 tail ESS 一致，bulk ESS 最大差约 1.02×10^{-12} ，不可判定位置一致。这不意味着重复计算后验函数也必然逐位相同，更不增加独立统计重复数。原短链的探索不足仍然成立。

实际数组传递同样是复现契约的一部分。第二轮启动时，Windows 重新生成的六份候选输入中，噪声与导数探测数组相同，但对数均匀数组有 82/49152 个元素不同，最大差约 4.44×10^{-16} ，因此原协议拒绝启动机制工作流。随后传递原始封存文件，按原哈希和容差完成了下述测量；原启动失败与候选数组仍保留。相同种子和依赖版本不能替代实际数组校验，核验本身也未确定底层数学库差异的因果来源。

7.1 Windows 有限机制测量

独立机制协议在 G1、G2、L1 上各使用 2 份主随机输入，比较窗口 4/16、链数分配及预先规定的 G2 RWM 步长对照。CPU 与 CUDA 各完成 96 个工作流；每个工作流包括首次审计、3 次交错缓存重放和探针后重放。全部 960 份保存路径通过独立 NumPy 参考核验，接受事件零失配，最大绝对路径差为 3.84×10^{-10} 。技术重放、窗口变体和跨设备副本均不增加独立输入数。

测量使用同一台 Windows 11 计算机的 Ryzen 7 9800X3D 和 RTX 5080，torch 主机线程设为 4，CUDA 使用 float64 并显式同步。桌面显示负载仍存在，不将线程数等同独占物理核心数。表8给出全部配置的描述性比值；它们来自三次缓存 sample 时间中位数之比，既不是完整推断成本比，也不是跨独立重复的置信区间。

设备/执行器	配对数	比值大于 1	全部比值范围
CPU / quasi-DEER	24	0	0.092–0.322
CPU / Picard	36	20	0.612–3.574
CUDA / quasi-DEER	24	0	0.139–0.437
CUDA / Picard	36	32	0.778–4.805

表 8: 机制协议的同核缓存执行比值：同组顺序时间除以时间执行器时间。全部 120 个时间执行配置均保留；quasi-DEER 对应 MALA，Picard 对应 RWM。每模型仅两份独立输入，配对数不能解释为独立实验数。

quasi-DEER 每个输出转移对应 7.75–22.5 次前向映射及 3.875–11.25 次 JVP；Picard 为 2–7.59375 次前向映射（图5）。这些计数包括拒绝自环，均高于顺序执行的一次前向映射；映射与 JVP 不是等价浮点工作量，不能简单相加。每端 6 个工作流完全零接受，全部保留。例如 G2/RWM 步长 1.0 的第一份输入，在窗口 4/16 下可一次确认整个窗口，同时没有接受移动。因此较长的确认前缀可以由自环产生，并不表示更有效的后验探索。

预先规定的等 512 个总输出对照提供了另一种解释边界。在 G2、L1 的两份输入及两个设备上，16 条各 32 步的顺序链均比单条 512 步、窗口 16 的 Picard 链更快，后者时间为前者的 4.43–6.92 倍。这 8 个技术对照说明链数分配会改变执行吞吐；两种分配的轨迹长度、初始化份数及探索能力不同，不能解释为相同推断精度下的优劣。图示的




图 5: Windows 机制测量中的重复求值与缓存成本。每点为一个配置与实际输入的组合，共 120 点，部分重叠；颜色区分目标，点形区分窗口。上下行为 CPU/CUDA，左右列为 quasi-DEER/Picard。纵轴大于 1 表示指定缓存执行较短；横轴包括拒绝自环。三次技术重放不扩充独立样本量，图中没有推断精度或统计区间。操作探针存在重叠，不用于构造可加的独占耗时分解。

额外工作量与 quasi-DEER 减速相容，但不足以唯一归因于 JVP、扫描或主机控制；固定状态操作探针与生产路径不同，同步及嵌套操作也使各阶段不能相加还原总时间。

7.2 批次运行与安装的实测范围

另一个 Windows 技术批次完成 27 项主任务和 24 项缓存探测（96 次调用），包含最大形状、进程集合管理和终态恢复检查。接收端对保存 MH 数组独立重放，并核对函数与 R 诊断；这没有新增正式推断重复。90 条函数诊断中仍有 59 条 $\hat{R} > 1.01$ 及 27 条 tail ESS 不可判定，不能将运行成功解释为收敛。该批次支持其封存运行器的技术能力；后继适配版本另经独立原生验收与接收核对，见第 7.3 节。

Python 0.2.0.dev2 与 R 0.2.0.9002 候选已在 Windows 新建依赖环境和仓库外完成安装核验，覆盖 CPU/CUDA MH 和 R 批量入口。默认 R 包检查与显式集成测试分别保存；成功检查不隐去此前安装和 locale 失败。接收端核对源码、sdist、wheel 与 R 包中 17 个模块，并从保存 RDS 重建诊断，没有在 Mac 重新测量 CUDA。该证据不涵盖原生 Windows 的 JAX/Stan 安装、GPU NUTS 或第三方团队的独立复现。

7.3 原生适配与独立接收的验证层次

任务执行、证据归档和统计解释分别接受核验。独立冻结的原生适配验收在 G1、G2 和水井 W1 各使用一份实际输入，运行 27 项四链主任务及 24 项缓存探测；G1/W1 每链保留 64 步，G2 保留 16384 步。接受原生进程、故障隔离、恢复和身份拒绝检查后，主任务全部返回数值合格结果，缓存 96 次调用仍无普通后验样本资格。前期句柄及测试环境失败、失败测试尝试与修复记录一并归档，没有将测试重试计为新的科学拟合。

接收端在 Mac 上按完整任务表重读原始证据，对 24 项 MH 主工作流及全部缓存调用独立重放 NumPy 递推，接受事件失配均为 0；三项 CPU NUTS 按数组、随机状态、适应记录和子进程证据核对，不作 MH 同路径声明。随后从原始函数二进制重建全部 117 条 R 诊断，按既定跨平台输出条件通过比较；这与早期要求原尺度输出逐位相等的检查是不同契约，没有将此前 60 份严格变换失败改为通过。恢复分析复用 51 项结果，未重新采样或重算诊断，原始文件不变。

数值合格仍不能解释为后验探索充分：本次 117 条函数记录中，83 条有限 $\hat{R}$ 大于 1.01，9 条 $\hat{R}$ 及 27 条 tail ESS 不可判定。这些记录共享每个目标的一份输入，不能据工作流或缓存调用数建立正式独立重复区间。逐函数诊断、跨平台末位差、数值库警告及原生故障链见配套接收报告；当前证据支持该固定适配版本的有限运行与接收能力，九目标多预算的正式推断比较仍未冻结或执行。

7.4 外部目标与测量接口

水井案例采用 posteriordb 的 3020 个观测，保留原模型中截距和距离系数的平坦先验，而非用带正态先验的内置 logistic 替代。通过两个不同距离上均出现两种结局的观

测，可构造可积的似然上界；本数据的后验因而可正规化。Stan、NumPy 和 torch 的密度及导数对照、固定输入轨迹与 R 数组传输已核验，Windows 的 12 项接口工作流也已独立重放。这些是目标和软件扩展证据；短链的明显不良诊断仍保留。有限参考样本与数值求积另行核对，未认证的罕见事件概率不能改写成解析真值。该案例已用于开发，不能再作为未见模型族的泛化检验。

后续充分预算比较需要将可用输出和完整成本对应到同一批重复。为此，已实现三种分别记录的测量口径：准备后、显式同步的内核执行；包含进程启动、输入读取、采样、变换、普通输出与 R 诊断的批量工作流；以及进一步包含独立轨迹参考、资源检查和封存的研究审计调用。后两者为嵌套边界，不能相加。给定核参数和已封存输入的普通工作流不包含事先调参、环境安装或最外层 R 前端；这些费用须另列。后续终态核验也独立登记，不因增加检查次数而改变第一次推断的成本。

一次完整四链拟合是重复单位，链、缓存重放和基础设施重试不增加重复数。任何一次实际尝试缺少计时回执时，该任务的完整成本保持未知，已知部分仍保留。对函数 f ，误差和成本坐标使用同一组数值有效且函数估计有限的重复；其中任何任务缺完整成本，不能通过删去它来生成横坐标。函数不可计算、参考未确定、数值失败和基础设施中断分别记录。共同可用重复上的成对费用比与误差差也采用同一集合，避免混合不同条件样本。

上述归并与统计接口已连接有限原生适配批次的实际证据；完整任务表、缓存资格、跨系统函数诊断及零重算恢复均有接收回执。该方法准备没有追溯替换历史 CPU 或 Windows 首轮的计时与 bootstrap 规则，也不为尚未执行的正式推断提供结果。

8 首轮 Windows 的 CPU 配对点

参考文献

- [1] Zoltowski D.M., Wu S., Gonzalez X., et al. [Parallelizing MCMC Across the Sequence Length](#). Advances in Neural Information Processing Systems, 2025, 38.
- [2] Grazzi S., Zanella G. [Parallel computations for Metropolis Markov chains with Picard maps](#). Biometrika, 2026, 113(2): asag022.
- [3] Carpenter B., Gelman A., Hoffman M.D., et al. [Stan: A Probabilistic Programming Language](#). Journal of Statistical Software, 2017, 76(1): 1–32.
- [4] Roualdes E.A., Ward B., Carpenter B., Seyboldt A., Axen S.D. [BridgeStan: Efficient in-memory access to the methods of a Stan model](#). Journal of Open Source Software, 2023, 8(87):5236.
- [5] Cabezas A., Corenflos A., Lao J., Louf R., et al. [BlackJAX: Composable Bayesian inference in JAX](#). arXiv:2402.10797, 2024.




图 6: 首轮 Windows CPU 全部配对输入的缓存速度比。四个点为每格四份实际数组; 黑色短线为中位数, 不作置信区间。两个面板依次对应 quasi-DEER MALA 与 Picard RWM。

- [6] Bingham E., Chen J.P., Jankowiak M., et al. [Pyro: Deep Universal Probabilistic Programming](#). Journal of Machine Learning Research, 2019, 20(28):1–6.
- [7] NIMBLE development team. [compareMCMCs: Tools for comparing MCMC efficiency from NIMBLE and other engines](#). 软件作者仓库, 访问于 2026 年 10 月 3 日。
- [8] Kulkarni S., Shah K.D., Arora N., et al. [PPL Bench: Evaluation Framework For Probabilistic Programming Languages](#). arXiv:2010.08886v1, 2020. 软件来源: <https://github.com/facebookresearch/pplbench>。
- [9] Magnusson M., Torgander J., Bürkner P.-C., Zhang L., Carpenter B., Vehtari A. [posteriordb: Testing, Benchmarking and Developing Bayesian Inference Algorithms](#). Proceedings of Machine Learning Research, 2025, 258:1198–1206.
- [10] Stan development team. [posterior: Rhat, bulk ESS and tail ESS documentation](#). 软件文档, 版本 1.7.0.
- [11] Senne R. and contributors. [ParallelMCMC.jl](#). 软件仓库, 提交 7be9c86, 访问于 2026 年 10 月 6 日。
- [12] Sosa S. [BayesForge: Bayesian Inference using numpyro and XLA](#). R 包 0.0.1 参考手册, 访问于 2026 年 10 月 6 日。
- [13] Hoffman M.D., Sountsov P. [Tuning-Free Generalized Hamiltonian Monte Carlo](#). Proceedings of Machine Learning Research, 2022, 151:7799–7813.
- [14] Robnik J., Seljak U. [Faster Parallel MCMC: Metropolis Adjustment Is Best Served Warm](#). Proceedings of Machine Learning Research, 2026, 300:2719–2727.
- [15] Dance H., Glaser P., Orbanz P., Adams R.P. [Efficiently Vectorized MCMC on Modern Accelerators](#). Proceedings of Machine Learning Research, 2025, 267:12436–12458.
- [16] Gonzalez X., Warrington A., Smith J.T.H., Linderman S.W. [Towards Scalable and Stable Parallelization of Nonlinear RNNs](#). arXiv:2407.19115v3, 2025 (初版 2024) .
- [17] Vehtari A., Gelman A., Simpson D., Carpenter B., Bürkner P.-C. [Rank-Normalization, Folding, and Localization: An Improved R-hat for Assessing Convergence of MCMC](#). Bayesian Analysis, 2021, 16(2):667–718.
- [18] Modrák M., Moon A.H., Kim S., et al. [Simulation-Based Calibration Checking for Bayesian Computation: The Choice of Test Quantities Shapes Sensitivity](#). Bayesian Analysis. DOI:10.1214/23-BA1404.