

ParallelBayes：时间并行 MCMC 的可核验实现与成本评估

中文研究稿：作者与单位待定

2026 年 10 月

摘要

时间并行 MCMC 同时求解多个采样位置，尝试缩短单条轨迹的计算时间。本文介绍带 R 接口的研究软件 ParallelBayes，将目标、转移核和执行器分开，在固定实际随机输入下比较顺序执行、窗口 quasi-DEER MALA 与 Online Picard RWM。九个目标、两档预算的 CPU/CUDA 研究中，3888 项主任务有 3741 项通过数值标准，42 项数值失败和 105 项进程失败均保留。普通工作流的组内配对几何平均速度比在 CPU 上为 Picard 0.424–1.178，在 CUDA 上为 0.953–1.659；quasi-DEER 的全部组均慢于对应顺序实现。窗口对照显示，批处理机会可被重复求值和较慢的前缀推进抵消。水井案例进一步显示，函数误差较小的配置并不一定具有最低的调用成本；双峰目标的合并符号比例则可由均衡初值维持，而非来自跨峰探索。独立原数组重建、完整失败记录与 R 调用测量共同表明，时间执行收益需要结合数值输出标准、具体函数和工作流边界评价。

1 引言

MCMC 以相邻状态的递推依赖换取对复杂后验的可计算访问。多链并行同时运行多条轨迹；时间并行则尝试同时求解同一条轨迹中的多个位置。Newton 类路径求解与增量 Picard 提供了两条具体路线 [1, 2]，但并行求值还会引入重复工作、导数近似和同步，其局部执行收益是否保留到后验推断，需要区别考察。

本文围绕两个问题展开：固定核参数、初值及实际随机输入时，时间执行能否更快完成同一递推；允许不同核采用各自配置后，所选后验函数的误差与 workflows 成本如何变化。第一类比较控制轨迹的统计信息，第二类同时受初始化、调参和混合影响。本文实现 ParallelBayes，为这两类比较提供可复用目标接口、独立路径参考、实际输入与失败记录，并用指定 CPU/CUDA 条件下的实验解释成本差异。

模型访问与推断组件复用 Stan、BridgeStan、BlackJAX 和 Pyro[3, 4, 5, 6]。compareMCMCs、PPL Bench 与 posteriordb 已有跨引擎运行、基准或参考目标支持 [7, 8, 9]；ParallelMCMC.jl 和 BayesForge 分别覆盖时间并行 MALA 接口与 R/JAX 建模路线 [11, 12]。本文增加的是同一实际输入下的执行比较和数值核验流程，以及这些流程揭示

的成本与探索差异，不以统一 R 接口本身作为创新依据。研究限于固定维度连续参数、两类 MH 时间执行和成熟 NUTS 基线。

2 方法与软件设计

2.1 目标与坐标

设 T 为相应自由坐标间的可微一一变换，原参数为 $\theta = T(q)$ ，计算使用无约束坐标 $q \in \mathbb{R}^d$ ，目标为

$$\ell(q) = \log p(y, T(q)) + \log |\det J_T(q)|. \quad (1)$$

模型记录参数顺序、约束映射、完整数据、实现版本与指纹。两个提供方式可省略不同的参数无关常数，因此以 $\ell(q) - \ell(q_0)$ 、同坐标梯度及变换结果核对目标。正值测试例使用 $\theta = \exp(q)$ 和 lognormal 密度，其 $-\log \theta$ 项与 Jacobian 抵消。这一例同时用于检测遗漏 Jacobian 的实现错误。

R 是建模控制与分析入口。BridgeStan 在 CPU 上调用编译后的 C++ 密度和自动微分，Python 串行循环组织转移；原生 JAX 模型进入 JIT 和批处理；独立 torch 后端使用 NumPy 参考及显式 CPU/CUDA 执行，当前时间执行器仍含 Python 主机控制。Stan 模型指针不跨线程共享，Stan 内部线程关闭。此时高频调用边界的成本属于软件工作流，不能从跨后端差异直接推断并行算法的贡献。

目标入口与实测设备	顺序 RWM/MALA	Picard RWM / quasi-DEER MALA	NUTS
Stan/BridgeStan, Mac CPU	支持	不支持	不支持
明确 JAX 目标, CPU	支持	支持对应核	BlackJAX 顺序核
明确 torch 目标, Windows CPU	已核验	已核验, 主机控制	独立研究 CLI: Pyro 四链
明确 torch 目标, Windows CUDA	已核验	已核验, 主机控制	未接入/核验

表 1: 当前代码的支持范围与实测边界。CPU Pyro 基线是独立研究 CLI，不是 `pb_sample()` 的通用 torch NUTS 选项；四链并发也不是 NUTS 轨迹时间并行。原生 Windows Stan 编译尚未核验。支持数值输出不等于已证实后验精度。

R 函数 `pb_capabilities()` 查询包接口支持的组合；独立研究 CLI 另列运行契约，不能从表 1 推定全部路线都能由一个 R 函数调用。`pb_benchmark()` 只组织配置列表及 R 结果，正式协议冻结、检查点和完整证据管理依赖 Python CLI 及项目文件。Stan 模型没有默认独立轨迹参考，`audit=TRUE` 明确拒绝。扩展示例通过公开 Python Model 提

供 Poisson 目标及独立 NumPy 参考，R 经 reticulate 调用并转换为 posterior 对象；并非 `pb_model()` 可直接接收任意 R 闭包。




图 1: 当前软件路线与证据流。Stan 只连接 CPU 顺序核；JAX 和 torch 仅接受明确实现的目标。独立顺序参考须另外提供，Stan 入口没有默认参考。NUTS 使用自身随机流及预热，独立 Pyro CLI 另作记录。数值有效输出继续接受统计诊断，失败不能转为正常样本。

2.2 固定随机输入下的核

MALA 的步长约定为

$$q' = q + h\nabla\ell(q) + \sqrt{2h}z, \quad z \sim N(0, I_d). \quad (2)$$

接受对数比包含正反向提议密度：

$$a(q, q') = \ell(q') - \ell(q) - \frac{\|q - q' - h\nabla\ell(q')\|^2 - \|q' - q - h\nabla\ell(q)\|^2}{4h}. \quad (3)$$

当 $\log u < a(q, q')$ 时接受，否则保留 q 。随机游走 Metropolis (RWM) 使用 $q' = q + sz$ ，接受对数比为 $\ell(q') - \ell(q)$ 。拒绝产生的自环计为一个转移。本文的 h 不等于提议噪声标准差；这一约定在所有配对执行中固定。

随机输入由锁定 NumPy 版本下的 Philox 生成，采样与导数探测种子分开。比较固定的是噪声数组和对数均匀随机数组，而非跨软件的同名整数 seed。正式原始输出保存这些数组及其校验和。独立顺序参考使用 NumPy 密度、解析梯度和显式循环，不调用待核验的 JAX 或 torch 转移函数。跨系统重建派生浮点数组不保证逐位一致；重复执行应传递已封存的实际数组，再分别核对文件与数组哈希。

2.3 两类时间执行的共同数学对象

普通 MCMC 逐步生成状态。时间执行器先猜测一个窗口内的路径，再修正相邻状态的不一致。固定初值和实际随机输入后，每一步都是确定映射，顺序路径满足

$$q_t^* = F_t(q_{t-1}^*), \quad t = 1, \dots, W. \quad (4)$$

quasi-DEER 用近似导数修正窗口；Online Picard 用接受增量重建路径并提交连续一致的前缀。它们求解的是指定递推，核验比较的也必须是相同初值、核参数及随机数组。

quasi-DEER 的窗口修正。 给定第 k 轮路径，下一轮满足

$$q_t^{(k+1)} = F_t(q_{t-1}^{(k)}) + B_t^{(k)} \{q_{t-1}^{(k+1)} - q_{t-1}^{(k)}\}. \quad (5)$$

旧路径上的映射和矩阵可同时计算；随后把右侧整理为关于新前驱的仿射递推，用结合扫描求解。在精确算术、各次映射有定义、 $B_t^{(k)}$ 有限且仿射递推精确求解时，第 k 轮至少恢复前 k 个状态，因而长度 W 的窗口至多需 W 轮。原因是固定初值使第一步正确；若前 k 步已经正确，下一轮保持该前缀，并使第 $k+1$ 步的修正项为零。这是既有因果递推性质 [16, 1]，不依赖 B 必须为真实 Jacobian。它没有为浮点溢出、容差提前停止或一般后验误差提供保证。

硬前向与代理 Jacobian。 令 $b = \mathbf{1}\{\log u < a(q, q')\}$ 、sg 为停止梯度算子。本实现用

$$g = b + \sigma(a - \log u) - \text{sg}\{\sigma(a - \log u)\} \quad (6)$$

构造代理导数；前向仍返回硬接受/拒绝状态。torch 代码另以停止梯度包裹硬输出，使前向避免软表达式的舍入抵消。这里得到的是代理 Jacobian J_{proxy} ，不是硬 MH 映射的真实 Jacobian。每链、每时间位置采用一个实际 Rademacher 向量 v_t ，在窗口迭代中复用，并设置

$$B_t^{(k)} = \text{Diag}\left[\text{clip}\{v_t \odot (J_{\text{proxy},t}^{(k)} v_t), -1, 1\}\right]. \quad (7)$$

截断作用于导数近似，不作用于状态。固定探针的复用不支持额外声称每轮自适应矩阵的条件无偏估计。

原论文伪代码先取 $\log \alpha = \min(0, a)$ ，其平滑门控为 $\sigma(\min(0, a) - \log u)$ [1]；本项目归档提交 5e5b637 的上游 samplers.py 与本实现使用未截断的 a 。两种硬接受判据等

价，代理导数一般不同，故这里明确报告所测公式。本实现还采用非重叠窗口、重复窗口起点的初猜及硬残差停止，不使用上游的 NaN 归零或状态裁剪；性能比较针对该适配实现。

Online Picard 的增量和确认前缀。 已确认起点为 q_L 时，RWM 的固定输入增量及候选路径为

$$D_t^{(k)} = sz_t \mathbf{1} \left\{ \log u_t < \ell(q_{t-1}^{(k)} + sz_t) - \ell(q_{t-1}^{(k)}) \right\}, \quad (8)$$

$$q_t^{(k+1)} = q_L + \sum_{i=L+1}^t D_i^{(k)}. \quad (9)$$

在新路径的前驱上重算接受事件，只提交连续匹配的前缀。例如四个位置依次为“匹配、匹配、不匹配、匹配”，只能提交前两个。第四个位置的前驱尚未确认。由起点向后归纳，固定噪声下匹配的接受事件确定相同增量，因而确认前缀满足原递推 [2]。torch 批量执行对各链取最短确认长度共同推进，窗口尾部只处理实际存在的转移。浮点前缀和与顺序累加的次序不同，仍须分别检查路径差和接受事件。

2.4 数值输出标准与失败处理

quasi-DEER 停止条件为硬递推残差

$$r = \max_{t,j} \frac{|q_{t,j} - F_t(q_{t-1})_j|}{\text{atol} + \text{rtol}|F_t(q_{t-1})_j|} \leq 1. \quad (10)$$

它控制局部一致性，而非长路径误差。独立 NumPy 参考另要求接受事件零失配，且每链无约束路径最大差不超过 $100[\text{atol} + \text{rtol} \max(1, \max |q|)]$ ，本文协议的两种容差均为 10^{-10} 。100 倍系数是指定输出标准，不是误差传播界。全路径尺度会放宽小尺度坐标的阈值；后续逐坐标和函数差只能作为另列的描述，不能追溯改变原合格判据。

迭代耗尽、非有限值或独立审计失配的输出保留原记录，不转换为普通后验样本。当前 MH 实现把非有限提议密度统一视为失败；合法的支持集外提议密度 $-\infty$ 尚未一般地区分，因此有界支持目标的适用范围受限。NUTS 的发散与返回有限数组分别记录。显式顺序回退复用原数组重算整个轨迹并计入失败费用，本文实验不启用回退隐藏求解失败。

2.5 R 用户如何运行和扩展

安装版示例以二维 Poisson 回归为例， $y_i \sim \text{Poisson}(\exp(X_i\beta))$ 、 $\beta_j \sim N(0, 4)$ 。外部 Python 模型提供框架密度、独立 NumPy 密度/解析梯度和恒等参数变换；R 整批调用，再转换为 posterior 对象。以下为仓库中实际示例的调用顺序，环境变量在启动 R 前指定，输出使用不存在的新目录。

```
# Once: create the shared data and actual random arrays
python examples/installed_custom_target.py prepare \
  --output inputs
# Set R_LIBS_USER and RETICULATE_PYTHON before starting R
Rscript --vanilla examples/installed-custom-target.R \
  torch inputs output cpu
```

R 脚本核心调用如下；`example_dir` 定位随包交付的示例文件，`inputs/output` 为上述目录。

```
library(parallelbayes)
pb_environment("torch")
helper <- reticulate::import_from_path(
  "installed_custom_target", path = example_dir, convert = TRUE)
result <- helper$run_example(inputs, output, "torch", "cpu")
for (w in result$workflows) {
  if (!identical(w$status, "completed")) next
  draws <- posterior::as_draws_array(w$draws)
  print(posterior::summarise_draws(draws))
}
```

完整脚本同时核对安装模块来源和输入哈希，保存失败项、样本及诊断，并在数值检查失败时返回错误。该例已在 Mac 安装环境下运行 JAX/torch 与 R 入口，四链各 128 次转移用于说明接口；没有预热，不能作为推荐推断预算。它的 Windows/CUDA 组合尚未实测。水井案例另有 Windows CPU/CUDA/R 接口证据。`pb_model()` 不接收任意 R 闭包，Pyro CPU NUTS 也仍是独立研究 CLI。

3 核验方法与实验设计

3.1 实验身份、目标与独立单位

各批次回答不同问题，不能按任务数合并统计证据（表2）。同核配对共享初值、核参数和实际数组；链、缓存回放、跨设备副本均不增加独立重复数。历史 Mac 为 M4/16 GB、JAX float64；Windows 为 Ryzen 7 9800X3D、RTX 5080 和 torch float64，主机控制与同步成本保留。平台间同时改变实现和硬件，只能比较完整 workflow。

目标库涵盖独立与相关高斯 G1/G2、具有高斯后验的潜在 AR(1) A1、logistic L1/L2、中心化/非中心化漏斗 H1/H2、双峰 M1 和水井 W1。历史两轮不含 W1。H1/H2 以不同坐标采样，原尺度输出通过变换对应；相同数值步长不代表原尺度上的同一核，因此只在每个坐标表示内部配对执行。

证据批次	平台与 workflow	重复和保留预算	用途/当前状态
Mac 主实验	0.1.0, 五 workflow	每格 24 份四链输入; 256/2048	1920 项, 固定预算比较
Mac 修订/SBC	0.1.1, 解析生成模型	64 数据集; 五共享工 作流	配对解析校准检查
Windows 首轮	0.2.0.dev1, CPU/CUDA 四种 MH	每格 4 份四链输入; 128/512	512 项, 探索性执行比 较
Windows 机制	独立机制协议, CPU/CUDA	每模型 2 份输入; 窗 口 4/16	192 工作流; 机制描述
紧凑推断研究	独立冻结版本; 九工作 流	每目标 24 份四链输 入; 1024/4096	3888 主任务; 完整原数 组复核

表 2: 证据身份与用途。缓存回放和安装/恢复检查不计统计重复; 详细源码、环境及协议清单见补充材料与项目索引。

3.2 函数误差、参考和诊断

对预先规定的函数 f , 记录四链平均估计 $\hat{\mu}_{a,f}^{(r)}(N)$, 逐函数误差为

$$\hat{E}_{a,f}(N) = \frac{1}{R} \sum_{r=1}^R \frac{(\hat{\mu}_{a,f}^{(r)}(N) - \mu_f^*)^2}{s_f^2}. \quad (11)$$

有解析期望时这是重复 MSE 的估计; 有限 MCMC 参考下只能称参考平方差。历史分析还报告函数间最大值, 紧凑研究以逐函数结果为主。所有实际函数定义列于表3; 标准化已包含在部分函数本身, 其余函数没有转成相同实际意义的相对误差。当前误差计算的额外 $s_f = 1$ 。历史阈值 $\epsilon = 0.1$ 即平方误差 $\epsilon^2 = 0.01$, 对应函数单位中的 RMSE 0.1; 它是比较标尺, 不是每种应用都充分的精度要求。误差估计的重复不确定性和参考 MCSE 均另列, 不与 ϵ 混用。

目标 (函数数)	原尺度函数, 所有 $s_f = 1$	期望/参考
G1/G2/A1 (各 3)	$z, z^2, \mathbf{1}(z > 1), z = (\theta_1 - m_1)/\sqrt{\Sigma_{11}}$	0, 1, $1 - \Phi(1)$
L1/L2 (各 4)	$\theta_1, \theta_2, \sigma(\theta_1), \mathbf{1}(\theta_1 > 0)$	独立 NUTS 有限参考; L2 符号 事件未定
H1/H2 (各 4)	$v/3, \tanh(v/3), \mathbf{1}(x_1 > 0), \cos(x_1 e^{-v/2})$	0, 0, $1/2, e^{-1/2}$
M1 (4)	$\theta_1/\sqrt{1+\delta^2}, \mathbf{1}(\theta_1 > 0), \theta_2, \theta_2^2$	0, $1/2, 0, 1$; δ 为模式位置绝对值
W1 (7)	$\alpha, \beta, \alpha^2, \beta^2, \sigma(\alpha), \sigma(\alpha + \beta), \mathbf{1}(\beta > 0)$	非认证数值求积及独立有限参 考; 非解析真值

表 3: 九目标共 36 个函数; W1 两项预测概率对应 0 米和 100 米。完整数值参考与不确定性由固定参考契约提供。历史 $s_f = 1$ 口径保留, 不用正式样本方差重新归一化。

L2 参考的符号事件在 262144 个相关样本中恒零，不能据零经验方差填入零误差。W1 后验可正规化的证明不认证求积尾部或稀有事件精度。对有限参考的敏感性分析与条件于参考的统计区间分开给出。现代秩正态化/折叠 $\hat{R}$ 、bulk ESS 与 tail ESS 从完整样本计算 [17, 10]，常量输出保留不可判定；这些诊断不替代真实函数误差。

历史 Mac 采用 24 重复、4000 次逐点 bootstrap；原 Windows 每格只有 4 份输入，其 bootstrap 区间只作探索性描述，完整配对点移入补充材料。紧凑研究主任务按完整四链重复整体重采样，采用 9999 次逐点 BCa、至少 20 份共同可用重复；退化区间保留未定。缓存每格仅 4 份输入，不计算 BCa。失败率使用全部计划重复，误差/费用的成功条件统计明确标注；它们不等于包含失败损失的无条件风险。

3.3 调参、预算与三种成本边界

历史零初值和固定 MH 步长定义的是指定工作流。新紧凑研究沿用独立开发试验选定的仿射坐标和步长：每目标/核六个候选，每候选两份四链输入，按两次都合格后的平均 ESJD/d 选择。216 次计划开发运行中 212 次完成、4 次失败；该规则优化移动距离，不证明 ESS 或函数误差最优。正式 MH 初值在采样坐标中取 $N(0, 4I)$ ，M1 首坐标分置两侧；窗口 32，quasi-DEER 每窗口最多 2048 轮，Picard 最多 $N + 512$ 轮。CPU Pyro NUTS 使用四进程，每链预热 1024 步、目标接受率 0.8、最大树深 8；MH 舍弃 512 步。开发调参费用单列，不能隐记为零或假定每次拟合重新支付。

紧凑研究固定两档保留预算 1024/4096 及 24 重复。该设计因用户硬件与空间条件在旧大网格启动后修订，保留旧证据并用新身份和输入，不能称完全事前预注册。Windows 冻结执行源为 3a37a89，交付为 94bebec。Mac 从完整原件独立重建全部 4144 项主任务与缓存记录，再按冻结统计规则生成结果；实际恢复复用 4144 项，新增分析为零。缓存只在 G1/G2/L2/W1 各分配 64 个探测，合计 1024 次调用，其余目标没有计划缓存测量。两个已测预算点不用于插值精确达标时间。

计时分别回答三个问题：缓存执行衡量准备后的内核；普通批量工作流包含进程启动、输入/目标、适应或丢弃、采样、变换、输出和 R 诊断；研究审计另含独立顺序参考与完整证据检查。CUDA 边界显式同步，后两种口径为嵌套边界，不相加。历史 Mac 的普通内存口径只是从已有计时扣除审计的记账估计；后继进程测量才是直接观测。两者仍不含最外层 R 前端、环境安装和全局归档传输。R 前端另以一个既有 Poisson 输入、32 个串行新 R 进程和 64 次技术调用直接测量；普通与审计模式各自记录，不回填正式主任务。误差与时间使用同一组函数可用重复，缺少完整计时的任务不能通过删行产生曲线。

4 实验结果

4.1 路径一致性与统计校准是不同检查

紧凑研究的 3414 项有效 MH 主任务及 1024 次缓存调用由 Mac 独立重放，共 54448128 次转移，接受事件失配为零；主任务最大路径差为 2.91910×10^{-7} ，最大误差/原界限比为 0.884。另有 327 份 NUTS 有效输出通过其各自保存契约核对，未将它们称作 MH 同轨迹重放。

Mac 的 1920 项和 Windows 首轮 512 项均通过各自规定的数值输出检查，独立参考的接受事件零失配；最大路径差分别为 2.36×10^{-8} 和 5.212×10^{-10} 。两者容差尺度与实现不同，不能用这两个最大值作算法精度排名。跨系统诊断重建还发现小数读取与中位数末位变化影响秩诊断；改用实际二进制输入后，剩余差异定位于折叠分量，未改变相关任务诊断不良的判断。详细定位及失败记录进入补充材料。

紧凑研究的数值失败提供了另一种检验：42 份 H1/MALA 候选已经达到内部停止条件，外部路径审计仍将其排除。Mac 对这些候选的 602112 次转移独立复核后，42 份仍超过原路径界限，接受事件失配为零。其中 40 份来自 quasi-DEER，另 2 份为顺序 MALA。前者的最大归一化局部残差均不超过 1，说明局部递推停止与完整路径误差是不同条件；顺序实现也可能积累超出指定界限的浮点差异。失败候选不进入后验统计。

SBC 采用 $\theta \sim N(0, 1)$ 、 $y_j \mid \theta \sim N(\theta, 1)$, $j = 1, \dots, 8$ ，解析后验为 $N(\sum_j y_j/9, 1/9)$ 。在同一批 64 数据集上，解析 90% 区间覆盖 54 例；MALA 及其时间执行也覆盖 54 例，但与解析区间有 4 例覆盖分歧。RWM 及 NUTS 覆盖 53 例。总体比例接近不能说明逐数据集区间相同，五种工作流也不能算五份独立校准证据。端点、后验矩和数据依赖对数似然秩另列；测试量的选择决定 SBC 能发现哪些问题 [18]。

4.2 普通工作流的配对执行成本

紧凑研究的主要比较采用普通工作流费用，覆盖全部九目标、两预算和两个设备上的同核配对（图2）。Picard 的配对几何平均速度比在 CPU 上为 0.424–1.178，18 组中 7 组点估计超过 1；CUDA 上为 0.953–1.659，14 组超过 1。quasi-DEER 在 CPU 和 CUDA 上的范围分别为 0.116–0.394 和 0.234–0.408，全部低于 1。区间展示逐点不确定性，超过 1 的点数不等于已确证加速的组数。

这一普通费用比较比历史缓存收益更接近一次批量使用，但仍条件于给定核配置和成功输出。历史 Mac 两类时间执行的所有模型—预算组缓存中位速度比均小于 1；首轮 Windows CUDA Picard 的范围为 1.097–5.230，quasi-DEER 为 0.164–0.505。历史网格与本轮的调参、预算和费用边界不同，不能把范围的变化归因于单一因素。加入双方共有的独立审计成本又会把费用比推向 1，因此三种口径分别保留。




图 2: 全部 72 组普通工作流的同核费用比, 定义为顺序/时间执行; 点为配对几何平均, 线为条件 95% BCa 区间。颜色与形状区分两档保留预算, 右侧 n 依次为两预算的共同有效四链重复数。H1/MALA 的四组少于 20 份, 按冻结规则只画空心点。缓存与研究审计口径见完整结果附录。

4.3 为什么较快的执行未必提供更有用的样本

CUDA 的 A1/RWM、512 步配置中，Picard 缓存执行约快 4.09 倍，但提议全部被拒绝，链停在初值，执行器每轮可确认整个窗口。自环降低了路径求解难度，同时使后验探索失效。这一反例解释了确认前缀与统计效率的区别，不能只按每次确认转移的成本推荐执行器。

窗口扩大还会增加重复工作。Mac 机制实验中，G1 四链 Picard 将窗口 16 增至 64，每轮确认数的组中位数仍约 5.57，而前向映射次数由 5.50 升至 20.88 次/输出转移，缓存速度比从 0.402 降至 0.170。G2 单链 quasi-DEER 的平均窗口轮数由 11 升至 22.25，速度比从 0.051 降至 0.027。拒绝自环均计入分母，JVP 另计。

Windows 机制协议也包含 G2 RWM 步长对照、窗口 4/16 及链数分配。quasi-DEER 每输出转移需 7.75–22.5 次前向映射及 3.875–11.25 次 JVP；Picard 需 2–7.59375 次前向映射。部分零接受配置一次确认整个窗口。等 512 总输出的另八个对照中，16 条短顺序链比单条较长 Picard 链快 4.43–6.92 倍，但轨迹长度和初始化不同，不能据此比较共同精度。各模型只有两份机制输入，操作探针还会扰动执行；现有结果支持额外工作与减速相容，尚不能唯一分离 JVP、扫描和主机控制的因果贡献。

4.4 固定预算误差与探索诊断

在紧凑研究的 3741 份有效拟合中，所选函数共形成 14981 行诊断，5000 行的有限 $\hat{R} > 1.01$ ，另有 1290 行未定。函数行共享拟合，不是独立重复。完整结果附录保留九目标 36 函数的两个已测预算点、条件误差区间及相同集合上的费用；它们没有定义单次可观测停止准则，也没有插值得到精确达标时间。

全部 105 项未分类失败来自 4096 步 CPU Pyro NUTS，仍以原状态计入失败分母。日志显示工作进程异常终止，具体发生阶段未能确定。另有 48 份有效 A1/G2 长预算拟合的 192 条链，在 Pyro 内置 ESS 中各触发约 2 GiB 分配警告，返回旧诊断缺失；保存样本仍由 R 计算现代诊断。这些记录说明被测基线包含特定诊断实现，不能把整条工作流的失败与费用都解释为 NUTS 核的固有性质，也不能据警告推定全部 105 项失败的根因。

双峰目标还显示，正确的合并函数估计不一定来自充分的单链探索。紧凑研究的 412 份有效 M1 拟合中，411 份保存路径未穿越 $q_1 = 0$ ，其合并正侧比例却恰为 1/2：初值规定两条链在负侧、两条在正侧，等长合并自然保持这一比例。唯一例外是一次 1024 步 CPU NUTS 拟合的一条链穿越零点（图3）。这一现象不否定所有合并估计的准确性；已知模式权重时可另作分层估计。但符号函数的零经验误差不能替代单链探索及不确定性检查。20 份失败拟合另列，不进入有效拟合分母；有效拟合中的退化诊断仍保持未定。




图 3: 双峰目标的保存路径。上图为 CPU 顺序 RWM, 下图为完整 M1 审查中唯一出现符号穿越的 CPU NUTS 拟合, 两者为同一原重复和 1024 步预算, 初值相同但随机机制不同。绘出四链全部保留状态; q_1 为原参数首坐标。示例按上述事后规则选择, 不据两份拟合比较性能。

4.5 水井案例的推断任务

W1 使用 posteriordb 的 3020 个观测，模型为 $\Pr(y_i = 1) = \sigma(\alpha + \beta d_i/100)$ ，保留原模型对 α, β 的平坦先验。问题是距离与换井概率的关系，以及 0 米、100 米处预测概率的估计成本。两个不同距离处均出现异结局观测，足以证明该二维后验可正规化（补充材料附录）。Stan、NumPy、torch 密度及导数和 Windows 的 CPU/CUDA/R 数组路径已有核验。该案例已参与开发，不作为未见模型族测试。

表4比较 4096 步预算的所有工作流。CPU 顺序 RWM 的普通费用约 4.94 秒、 α 参考平方差约 2.06×10^{-6} ；CPU 顺序 MALA 约 10.58 秒、平方差约 0.58×10^{-6} ；CPU NUTS 约 11.62 秒、平方差约 0.28×10^{-6} 。同核时间执行没有改善这些轨迹的统计信息，却增加了本例的普通费用。这组结果给出已测预算上的成本与函数精度选择，不支持把某一核称为所有精度要求下的最优方法。

工作流	普通费用/秒	α 平方差 $\times 10^6$	β 平方差 $\times 10^6$
CPU RWM seq	4.94	2.06 [1.16, 3.40]	4.91 [2.72, 7.94]
CPU Picard	11.59	2.06 [1.16, 3.40]	4.91 [2.72, 7.94]
CUDA RWM seq	5.73	2.06 [1.16, 3.40]	4.91 [2.72, 7.94]
CUDA Picard	6.01	2.06 [1.16, 3.40]	4.91 [2.72, 7.94]
CPU MALA seq	10.58	0.58 [0.39, 0.89]	1.11 [0.68, 2.00]
CPU quasi-DEER	68.85	0.58 [0.39, 0.89]	1.11 [0.68, 2.00]
CUDA MALA seq	13.99	0.58 [0.39, 0.89]	1.11 [0.68, 2.00]
CUDA quasi-DEER	45.51	0.58 [0.39, 0.89]	1.11 [0.68, 2.00]
CPU NUTS	11.62	0.28 [0.14, 0.51]	0.52 [0.32, 0.84]

表 4: 水井 W1 在每链 4096 次保留转移下的普通费用均值和参考平方差。每行 24 份原始四链重复；方括号为条件 95% BCa 区间。参考为非认证数值求积，区间不含其不确定性。费用包含普通进程与 R 诊断，不含最外层 R 前端。其余五函数和 1024 步结果见完整结果附录。

4096 步下，六个非稀有函数的保存 $\hat{R}$ 均不超过 1.01；但 $\mathbf{1}(\beta > 0)$ 在所有拟合中恒零，诊断仍未定。对非认证求积给出的极小尾概率，接近零的平方差不能认证其相对精度。可正规化证明、常规系数估计和罕见事件估计在这里有不同的证据要求。

4.6 实际 R 调用的额外费用

有限 Poisson 补测直接记录新 R 进程启动到首次样本和诊断可用的延迟，以及同会话再次完整调用的费用。32 个进程、64 次调用均完成独立 NumPy 路径检查及 R 浮点字节核对，接受事件零失配；实际恢复没有新增调用。普通模式首次可用延迟的组中位数为 1.27–2.06 秒，同会话再次调用为 0.014–0.340 秒。首次普通 MALA 顺序调用中还出现 5.22 秒观测，完整保留；四次技术重放的范围和费用分解见补充材料。这项测

量补足 R 前端的使用边界，与 Windows 正式比较分别报告；短 Poisson 轨迹没有据此获得精度认证。

5 讨论与结论

本文的主要发现是，时间执行的收益同时受核、设备和费用边界影响。在所测 torch workflows 中，CUDA Picard 的多数模型—预算组具有较低的普通费用点估计，而 quasi-DEER 的额外工作未被抵消；真实水井案例中的时间执行也没有减少普通调用成本。机制对照与这些结果相容：窗口扩大增加同时求值的位置，也可能增加重复映射、JVP 和等待确认的工作。当前探针尚不能唯一分离扫描、导数和主机控制各自的因果贡献。

这种限定与原方法的收益并不冲突。Picard 原文在 Apple M3 上对由时滞微分方程定义的昂贵黑箱似然报告约 2.52 倍墙钟收益 [2]，成本结构不同于本文多数廉价目标。本文的窗口与停止规则也属于适配实现。后续若要判断昂贵似然的适用边界，需要预先控制单次求值成本和批处理吞吐，而不是从现有网格中挑选最快的配置。

数值恢复与后验探索还产生两种不同限制。H1 候选可达到局部残差条件却越过完整路径界限；M1 合并符号误差可因初值均衡而接近零，却缺少跨峰探索。前者需要保留明确输出标准与失败，后者需要共同解释函数、初始化和诊断。105 项 NUTS 进程失败及未定参考进一步限制了无条件方法排名：本文保留成功条件比较及全部失败费用，没有用额外成功重复替换它们。

ParallelBayes 的贡献是可复用的目标/核/执行分离、固定实际数组的独立核验，以及从原始结果重建的成本和误差证据。Stan 仍仅接 CPU 顺序核，Pyro NUTS 是独立研究 CLI，R 前端费用只在指定 Mac CPU 示例中直接测量。自动选择器、GPU NUTS 和 MEADS/LAPS 等更广的多链比较 [13, 14, 15] 不属于本版实测能力。现有结果支持按明确目标和费用边界使用该软件进行执行器研究；它们没有建立普遍推断加速或跨模型自动配置规则。

代码、数据与构建材料

源码、协议、分析摘要和论文输入见 [ParallelBayes GitHub 仓库](#)。历史 CPU 原始证据见 `cpu-review-v1` Release。Windows 紧凑原始证据在 2026 年 10 月 10 日核实时仍为草稿 Release；当前公开状态需在最终交付前再核实，不能由源码可克隆推定原数组公众可取。正文、补充材料及全 36 函数的独立结果附录提供构建入口和校验清单；原数组到统计和图文的步骤分别记录。保存分析到图文的重建不等于本轮重跑全部原始实验。

项目已有 Mac 与 Windows 安装及显式 R 集成证据；本稿中的外部目标示例使用公开接口。私有技能、第三方受限全文和本地环境不随公共材料发布。生成式工具辅助了代码、分析组织、图表与中文写作，相关陈述由实际记录及独立核验支撑；作者、单

位、最终公开范围与投稿仍由研究者确认。

参考文献

- [1] Zoltowski D.M., Wu S., Gonzalez X., et al. [Parallelizing MCMC Across the Sequence Length](#). Advances in Neural Information Processing Systems, 2025, 38.
- [2] Grazi S., Zanella G. [Parallel computations for Metropolis Markov chains with Picard maps](#). Biometrika, 2026, 113(2): asag022.
- [3] Carpenter B., Gelman A., Hoffman M.D., et al. [Stan: A Probabilistic Programming Language](#). Journal of Statistical Software, 2017, 76(1): 1–32.
- [4] Roualdes E.A., Ward B., Carpenter B., Seyboldt A., Axen S.D. [BridgeStan: Efficient in-memory access to the methods of a Stan model](#). Journal of Open Source Software, 2023, 8(87):5236.
- [5] Cabezas A., Corenflos A., Lao J., Louf R., et al. [BlackJAX: Composable Bayesian inference in JAX](#). arXiv:2402.10797, 2024.
- [6] Bingham E., Chen J.P., Jankowiak M., et al. [Pyro: Deep Universal Probabilistic Programming](#). Journal of Machine Learning Research, 2019, 20(28):1–6.
- [7] NIMBLE development team. [compareMCMCs: Tools for comparing MCMC efficiency from NIMBLE and other engines](#). 软件作者仓库, 访问于 2026 年 10 月 3 日。
- [8] Kulkarni S., Shah K.D., Arora N., et al. [PPL Bench: Evaluation Framework For Probabilistic Programming Languages](#). arXiv:2010.08886v1, 2020. 软件来源: <https://github.com/facebookresearch/pplbench>。
- [9] Magnusson M., Torgander J., Bürkner P.-C., Zhang L., Carpenter B., Vehtari A. [posteriordb: Testing, Benchmarking and Developing Bayesian Inference Algorithms](#). Proceedings of Machine Learning Research, 2025, 258:1198–1206.
- [10] Stan development team. [posterior: Rhat, bulk ESS and tail ESS documentation](#). 软件文档, 版本 1.7.0。
- [11] Senne R. and contributors. [ParallelMCMC.jl](#). 软件仓库, 提交 7be9c86, 访问于 2026 年 10 月 6 日。
- [12] Sosa S. [BayesForge: Bayesian Inference using numpyro and XLA](#). R 包 0.0.1 参考手册, 访问于 2026 年 10 月 6 日。
- [13] Hoffman M.D., Sountsov P. [Tuning-Free Generalized Hamiltonian Monte Carlo](#). Proceedings of Machine Learning Research, 2022, 151:7799–7813.
- [14] Robnik J., Seljak U. [Faster Parallel MCMC: Metropolis Adjustment Is Best Served Warm](#). Proceedings of Machine Learning Research, 2026, 300:2719–2727.
- [15] Dance H., Glaser P., Orbanz P., Adams R.P. [Efficiently Vectorized MCMC on Modern Accelerators](#). Proceedings of Machine Learning Research, 2025, 267:12436–12458.

- [16] Gonzalez X., Warrington A., Smith J.T.H., Linderman S.W. [Towards Scalable and Stable Parallelization of Nonlinear RNNs](#). arXiv:2407.19115v3, 2025 (初版 2024) .
- [17] Vehtari A., Gelman A., Simpson D., Carpenter B., Bürkner P.-C. [Rank-Normalization, Folding, and Localization: An Improved R-hat for Assessing Convergence of MCMC](#). Bayesian Analysis, 2021, 16(2):667–718.
- [18] Modrák M., Moon A.H., Kim S., et al. [Simulation-Based Calibration Checking for Bayesian Computation: The Choice of Test Quantities Shapes Sensitivity](#). Bayesian Analysis, 2025, 20(2):461–488. DOI:10.1214/23-BA1404.